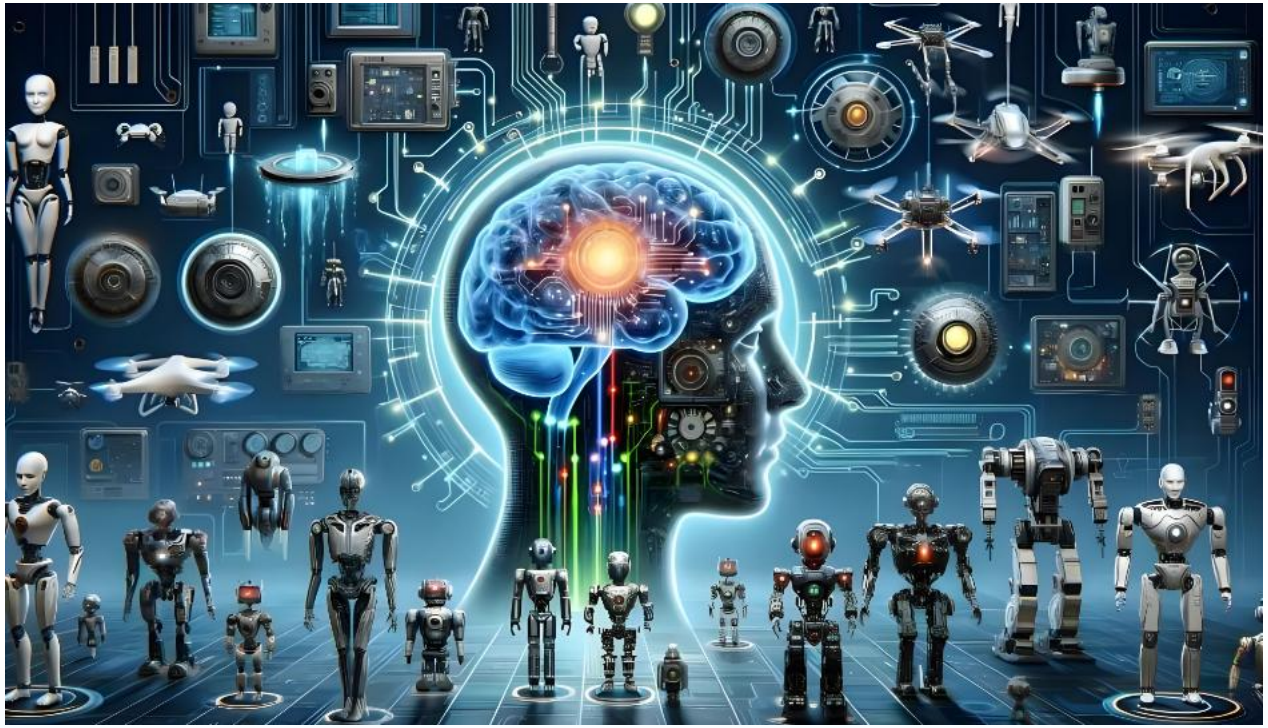
浙江大学
ZHEJIANG UNIVERSITY



期末复习

题型及关于代码的考试



代码考试题型

1、代码注释题：

```
import tensorflow as tf
from tensorflow.keras.models import Sequential
model.fit(x_train, y_train, epochs=10, batch_size=32)
```

2、选择题：

```
model.compile(optimizer='adam',
              loss='binary_crossentropy',
              metrics=['accuracy'])
```

3、问答题：输出是什么

比如：计算两个句子“天行健君子以自强不息”、“地势坤君子以厚德载物”的语义相似度

再比如：感知机模型的计算代码

整体试卷题型

判断20分（20题）

单选20分（20题）

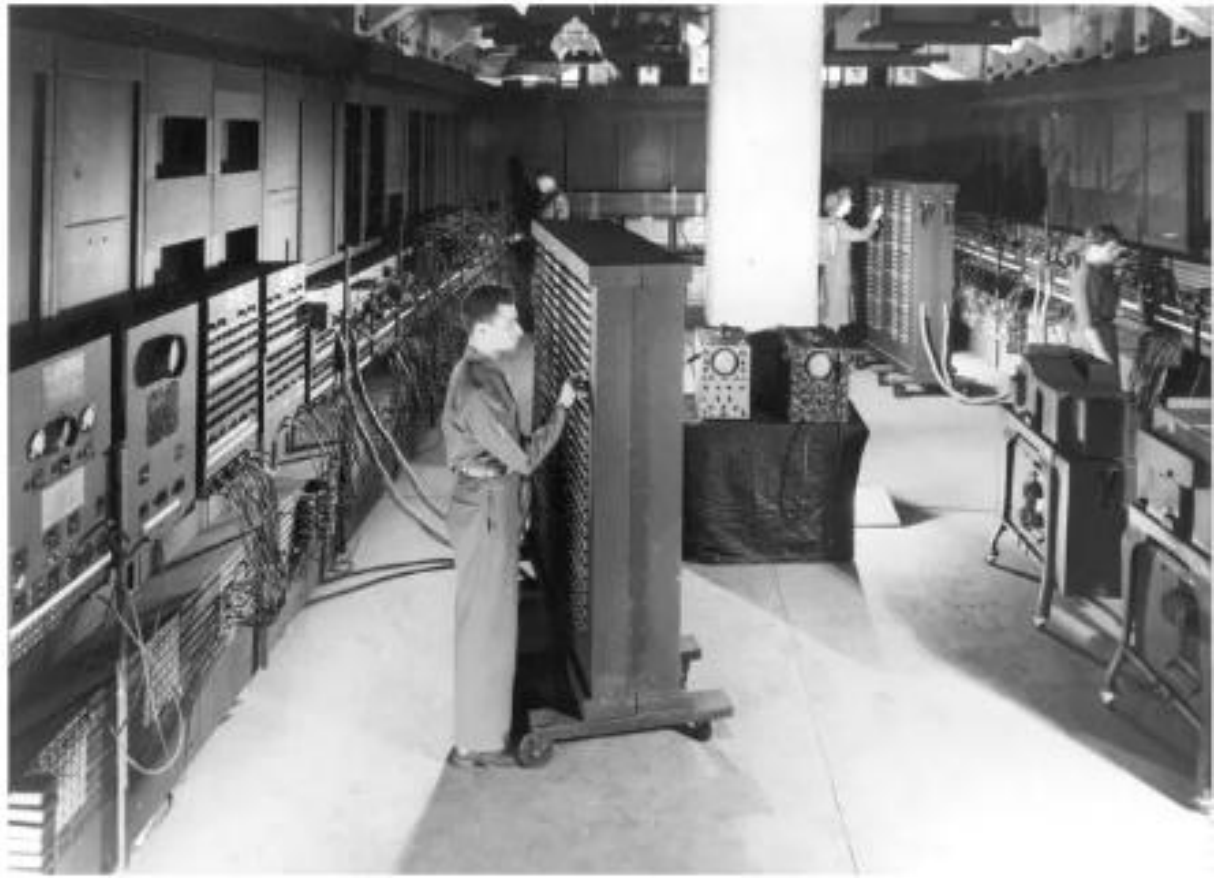
多选30分（15题）

计算15分（3题）

问答15（3题）

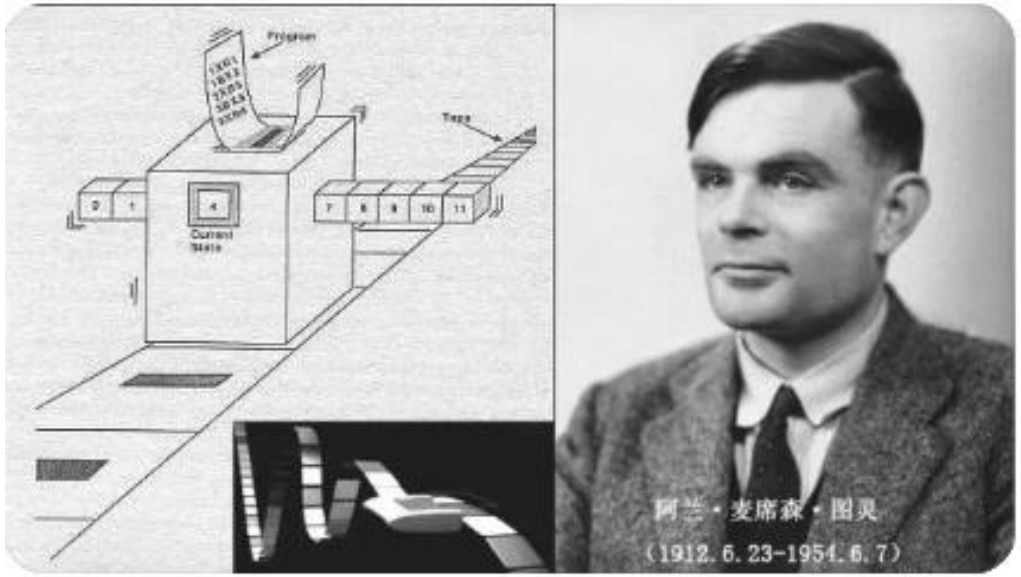
闭卷纸质考，没有补考，只能携带计算器，不能带手机、电脑等智能设备

现代人工智能起源

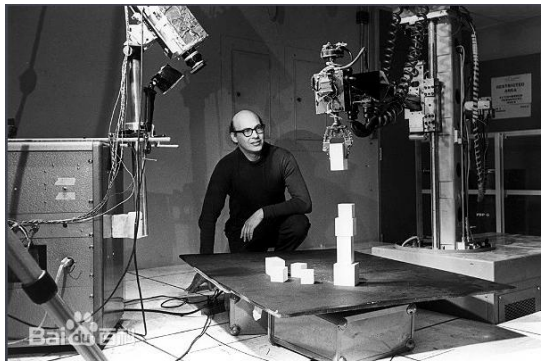


世界上第一台通用电子计算机：ENIAC

1946年，宾夕法尼亚大学



1950年 图灵的图灵机



1951年 马文·明斯基建造第一台神经网络计算机

图片来源：百度

里程碑——达特茅斯会议



1955年8月 提案

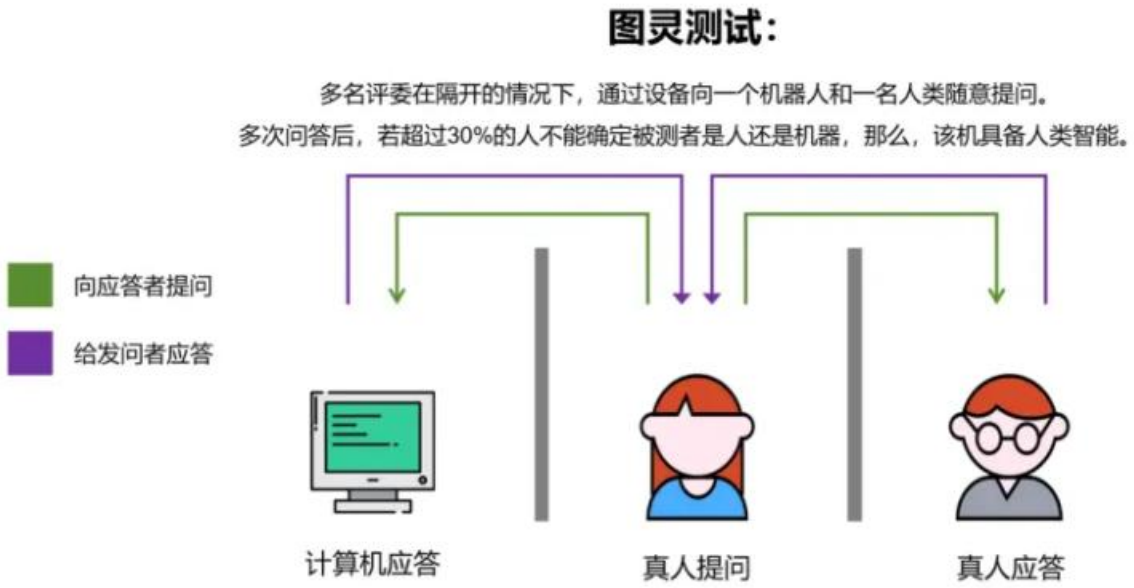
- 约翰.麦卡锡（达特摩斯学院）
- 马文.明斯基（哈佛）
- 克劳德.香农（贝尔实验室）
- 纳撒尼尔.罗切斯特（IBM）
- 洛克菲勒基金会

1956年8月 达特茅斯会议

- 首次正式提出人工智能
- 现代人工智能元年

图片来源：百度

关于机器智能的大辩论



通过编程和算法，计算机能真正理解和思考吗？

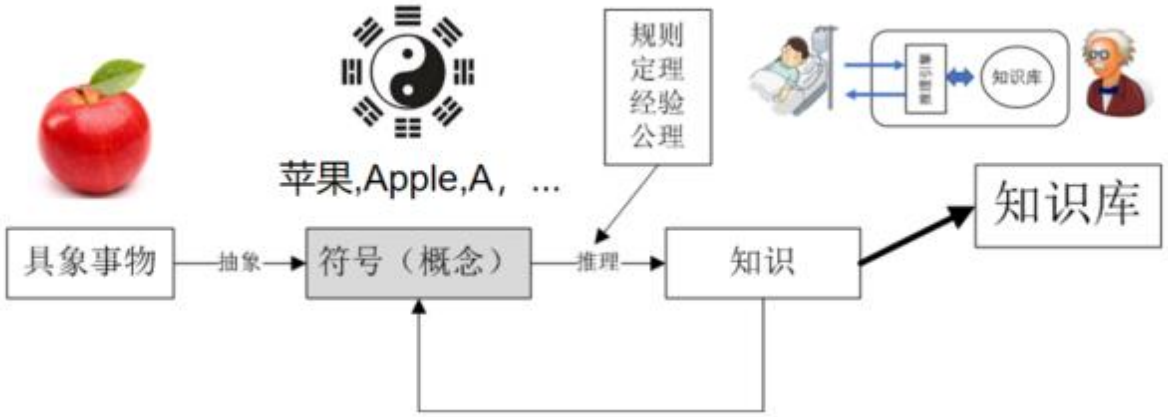
算法根据输入，执行了期望的行动，算智能吗？

图灵测试的结果还有效吗？

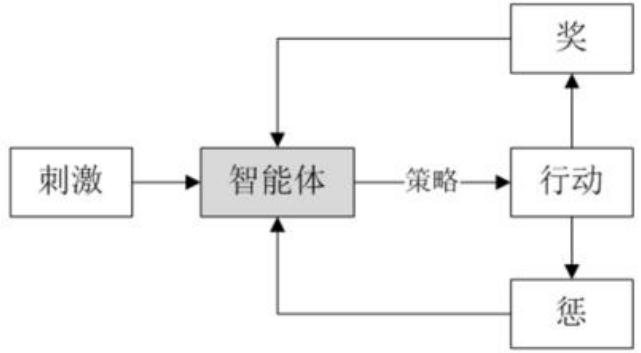


中文屋测试 约翰 塞尔

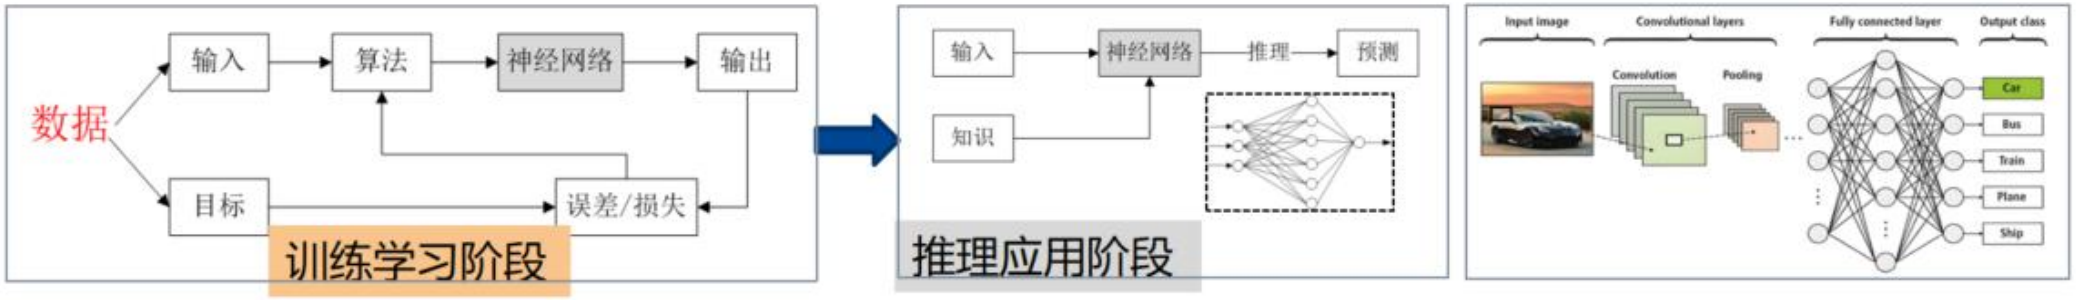
人工智能三大学派



符号主义

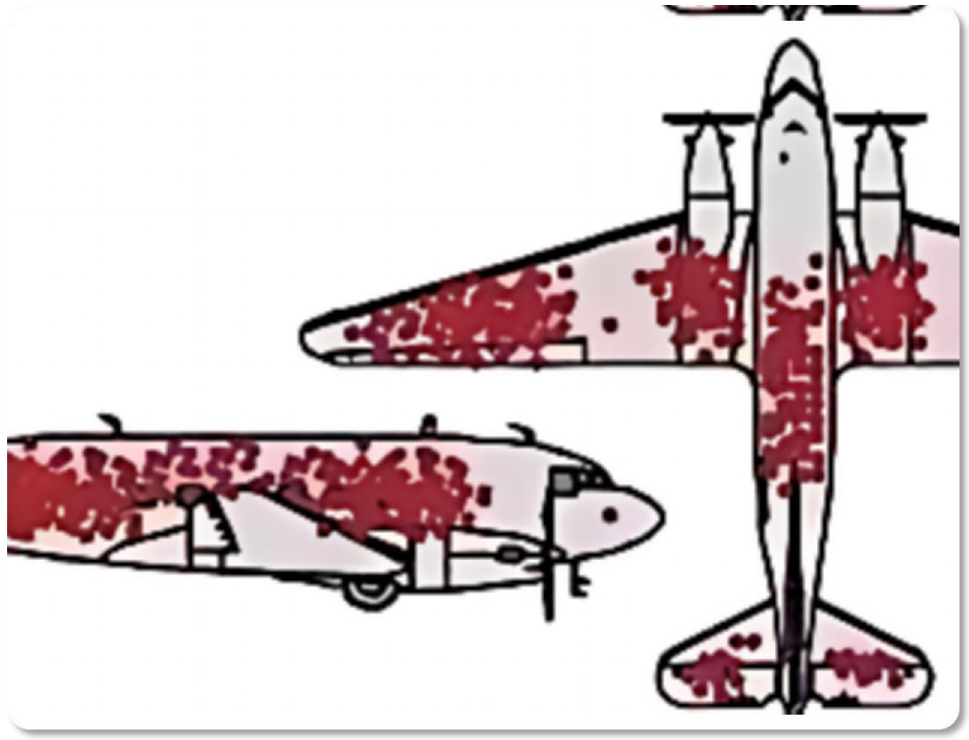


行为主义



联结主义

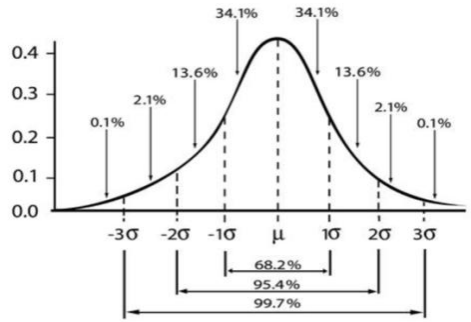
幸存者偏差 —— 沉默的大多数



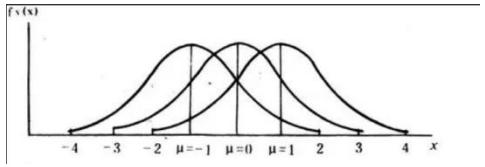
幸存者偏差，就是忽略了筛选条件，把经过筛选的结果当成随机结果。

AI的局限绝大多数起源于幸存者偏差现象

AI的使用条件：假设



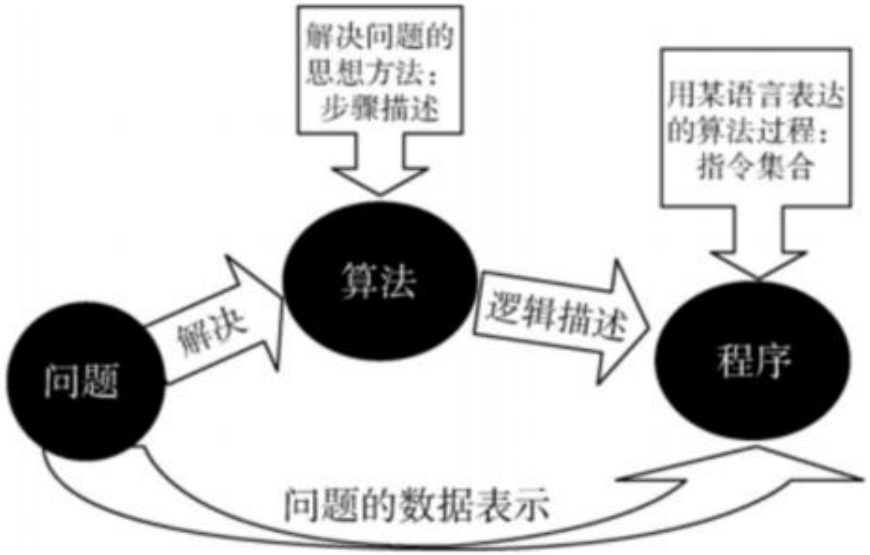
特征值的**正态分布**，如身高、血压

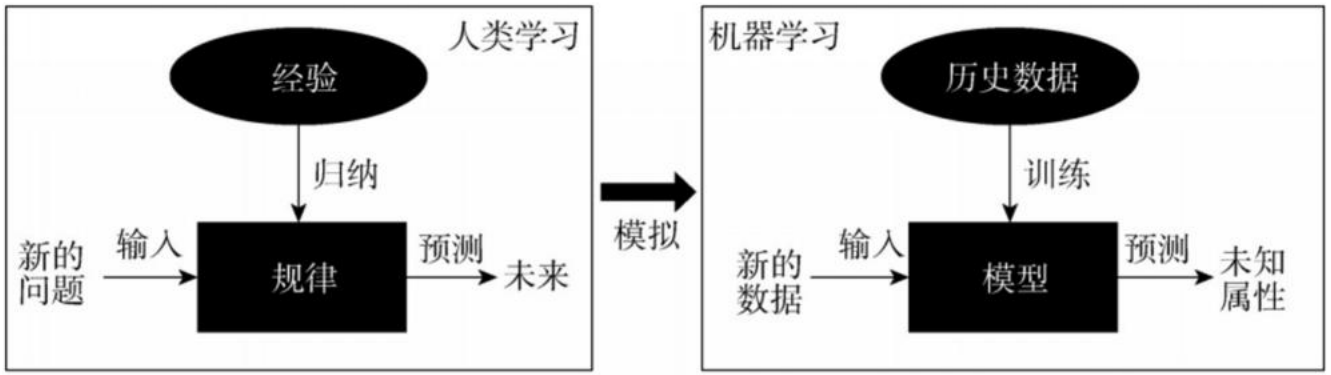


实际采样数据

图片来源：百度

通用问题求解

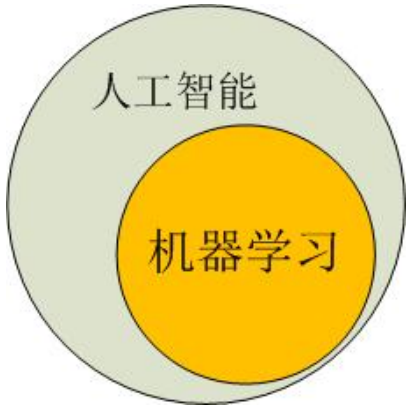




（a）人类学习求解　　（b）机器学习求解

从符号主义迈向机器学习

机器学习的定义



定义：已知一个数据集Dataset，其中输入X都存在与其对应的标签Y，通过计算机寻找一个数学模型F，使得对于所有X，Y'=F(X)尽可能的逼近Y,这个寻找过程就叫**机器学习**。

每一对X、Y又叫**样本**，总个数叫样本大小

Y的所有可能取值叫**样本空间**， Dataset是样本空间的一个随机抽样

机器学习是人工智能的子集

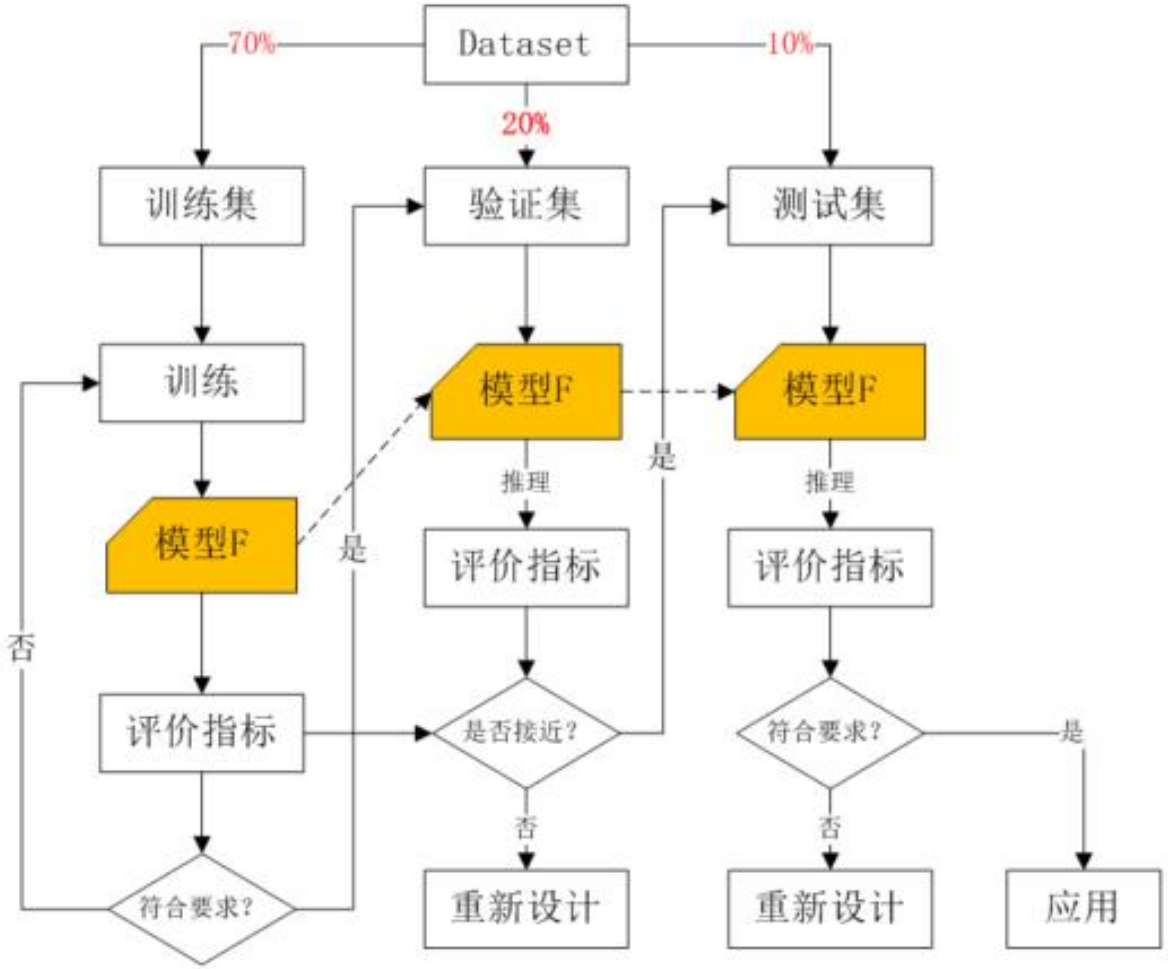
机器学习与非机器学习的区别：

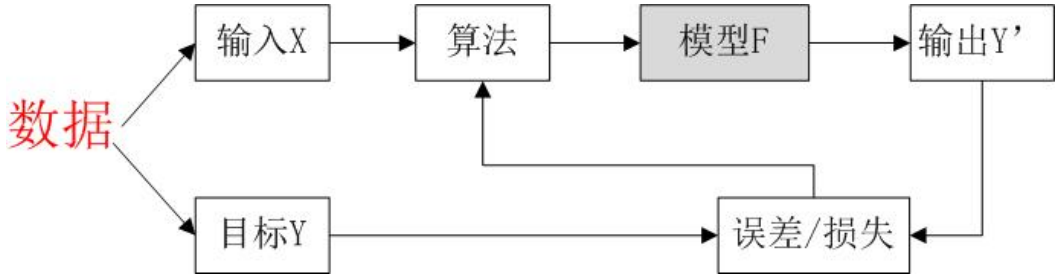
	机器学习	非机器学习
先验数据	必须	非必须
数学模型	推理模型+训练算法	推理模型
模型参数	计算机自动习得	人工设计
准确率	难以100%	容易达到100%
推理	采用计算机	采用计算机

讨论：下列哪些属于机器学习

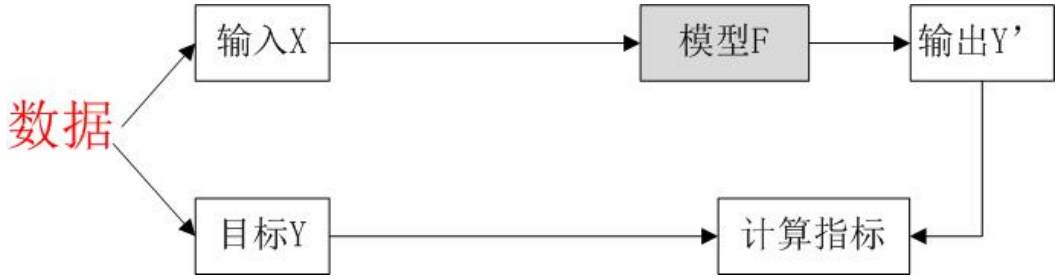
- 剪枝算法
- 深度优先算法
- 蒙特卡洛树搜索
- 启发式搜索
- 蚁群算法
- 宽度优先算法
- 最大-最小搜索
- 线性回归

机器学习过程





训练过程



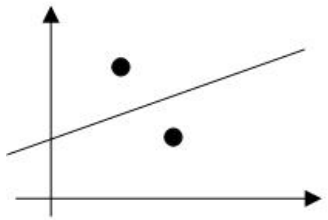
推理过程

五个要素

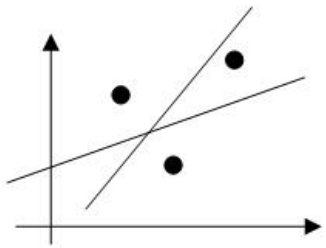
数据、模型、训练、预测和评估

思考：为什么要区分出测试集和验证集？

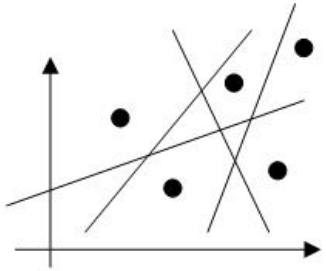
过拟合



1根线可分2个点

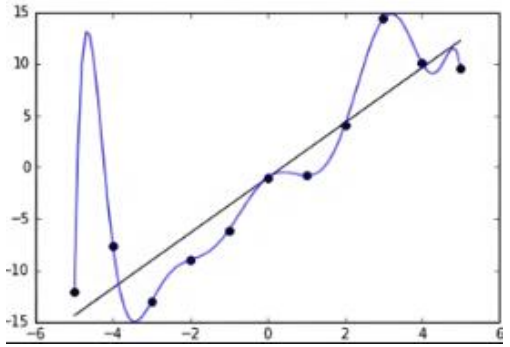


2根线可分3个点

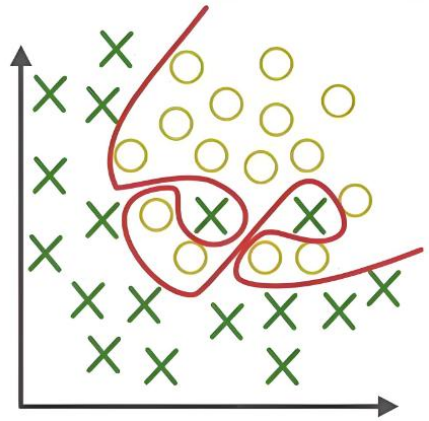


n根线可分n+1个点

根据泰勒展开原理 $f(x) = a_0 + a_1x + a_2x^2 + a_3x^3 + \ldots + a_nx^n$



非线性回归过拟合



过拟合：训练集上表现很好，预测时表现很差的现象

如何消除过拟合——提升泛化能力

1. 交叉验证
2. dropout：动态随机切断神经元的连接
3. 正则化：L1范式（LASSO回归）和L2范式（岭回归）
4. 不过度训练（实时监控）
5. 特征选择（难度较大，往往事与愿违，以偏盖全）
6. 集成学习，即多种不同质模型的组合投票
7. **核心：数据质量与预处理技术（正道）**

没有免费午餐定理（NFL）:Wolpert 和Macerday1997年在最优化理论中提出，指出“任何机器学习模型在所有问题上的性能都是相同的，其总误差和模型本身是没有关系的。一种算法（算法A）在特定数据集上的表现优于另一种算法（算法B）的同时，一定伴随着算法A在另外某一个特定的数据集上有着不如算法B的表现”

——**具体问题具体分析**

图片来源：百度

机器学习的分类



监督学习(supervised learning)
数据有标签、一般为回归或分类等任务

无监督学习(un-supervised learning)
数据无标签、一般为聚类或若干降维任务

强化学习(reinforcement learning)
序列数据决策学习，一般为与从环境交互中学习

半监督学习
(semi-supervised learning)

12

常用损失函数



(1) 回归损失函数，用于衡量回归系统的误差，常见的有如下几种：

均方误差（mean_squared_error）

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(T_i - Y_i)^2$$

平均绝对误差（mean_absolute_error）

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|T_i - Y_i|$$

平均绝对百分比误差（mean_absolute_percentage_error）

$$MAPE = \frac{1}{N}\sum_{i=1}^{N}|\frac{Y_i - T_i}{Y_i}| \times 100$$

均方根对数误差（mean_squared_logarithmic_error）

$$MSLE = \frac{1}{N}\sum_{i=1}^{N}[log(T_i + 1) - log(Y_i + 1)]^2$$

(2) 分类损失函数，用于衡量分类系统的误差

二进制交叉熵（binary_crossentropy）：用于二分类问题，对应的激活函数是sigmoid

$$Loss = -\frac{1}{N}\sum_{i=1}^{N}[Y_i \times logT_i + (1 - Y_i) \times (1 - T_i)]$$

多分类交叉熵（categorical_crossentropy）：用于多分类问题，对应的激活函数是softmax

$$Loss = -\frac{1}{N}\sum_{i=1}^{N}Y_i \times logT_i$$

终止条件

1、Loss足够小
2、ΔLoss足够小
3、训练次数
4、梯度接近0
5、……

聚类



- 聚类是指把**特征相似**的样本聚成一组，同组成员有相似的属性。即**物以类聚，人以群分**
- 聚类是一种**无监督学习**，算法的核心思想是通过计算数据点之间的**相似度**或距离（**欧式距离**），将相似的数据点聚集在一起形成簇。

- 两个m维数据之间的欧氏距离为

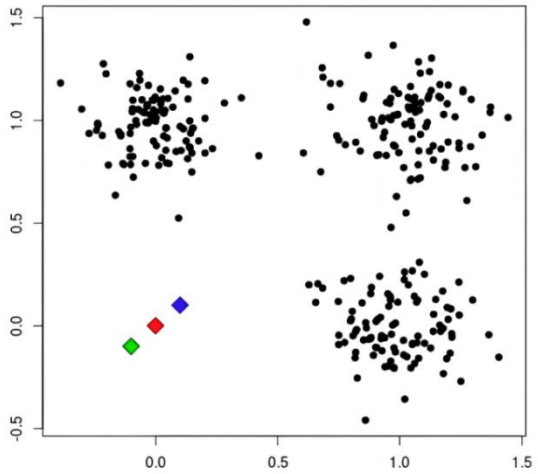
$$d(x_i, x_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + \ldots + (x_{im} - x_{jm})^2}$$

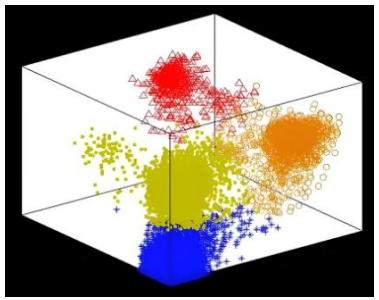
$d(x_i, x_j)$值越小，表示x_i和x_j越相似；反之越不相似

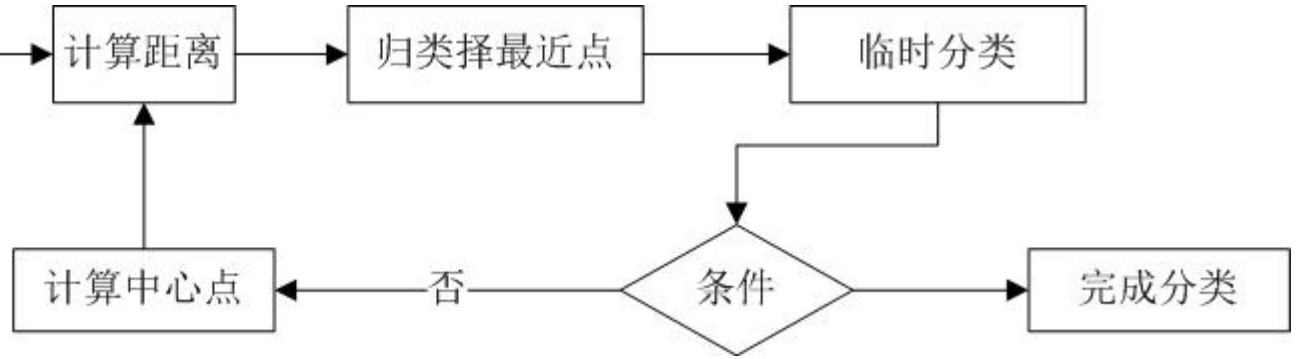
——问题——

如何将n个数据依据其相似度大小将它们分别聚类到k个集合，使得每个数据仅属于一个聚类集合。

K-means算法





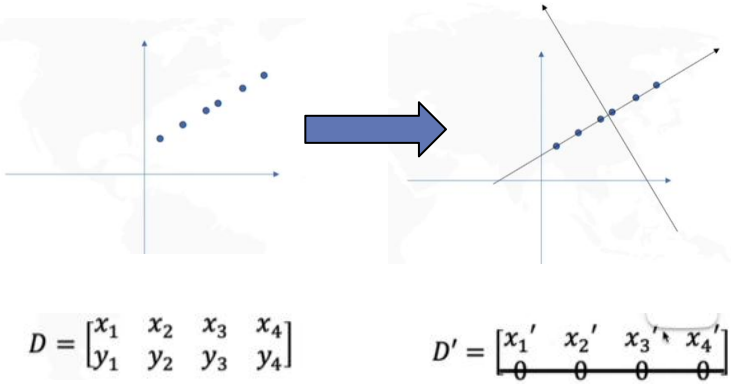


K-means 算法（ K=3 ） 无监督学习

第一步：随机初始化聚类质心 **第二步：计算每个数据到质心的距离，并归类到最近的距离** **第三步：重新计算每类的质心** **第四步：重复循环第二、三步，直到满足条件**	**条件：** **1、达到跌代次数** **2、前后2次迭代中，聚类质心基本不变，趋于稳定状态**

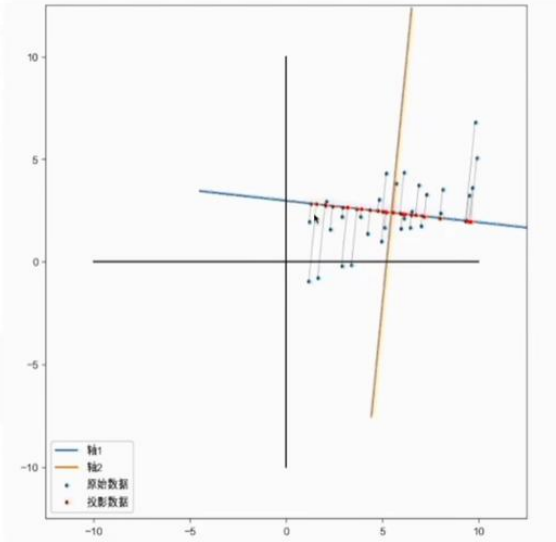
K-means演示： http://alekseynp.com/viz/k-means.html

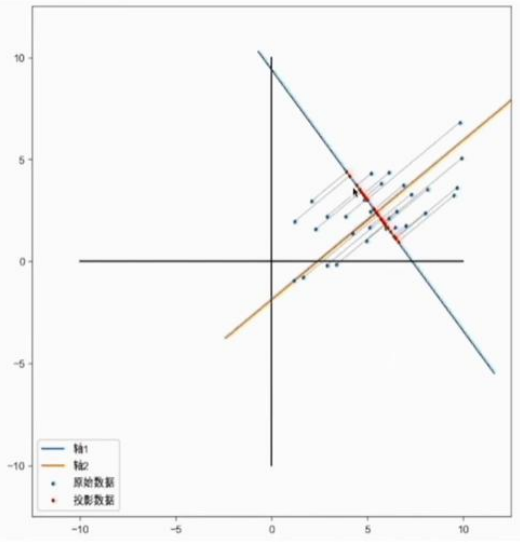
降维——主成分分析（PCA）



$$D=\begin{bmatrix}x_1 & x_2 & x_3 & x_4\\ y_1 & y_2 & y_3 & y_4\end{bmatrix}$$

$$D'=\begin{bmatrix}x_1' & x_2' & x_3' & x_4'\\ 0 & 0 & 0 & 0\end{bmatrix}$$

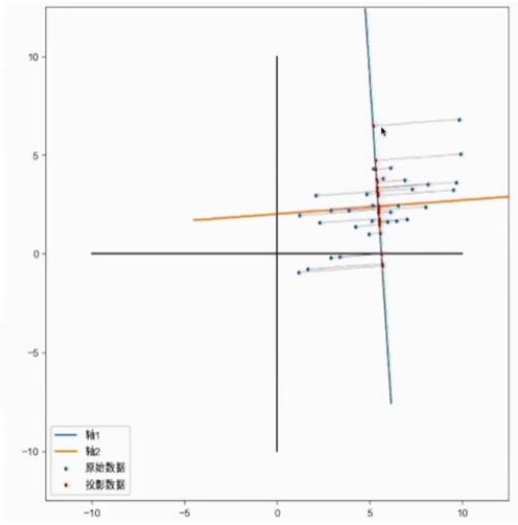


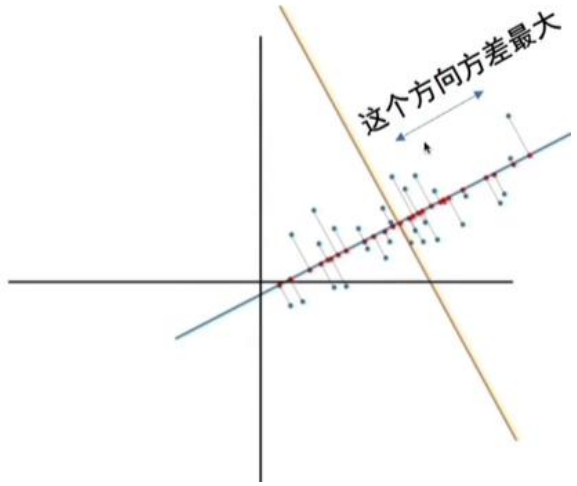


原理：通过建立一个新的坐标系，将多个维度的数据投影到该坐标系，实现数据的降维

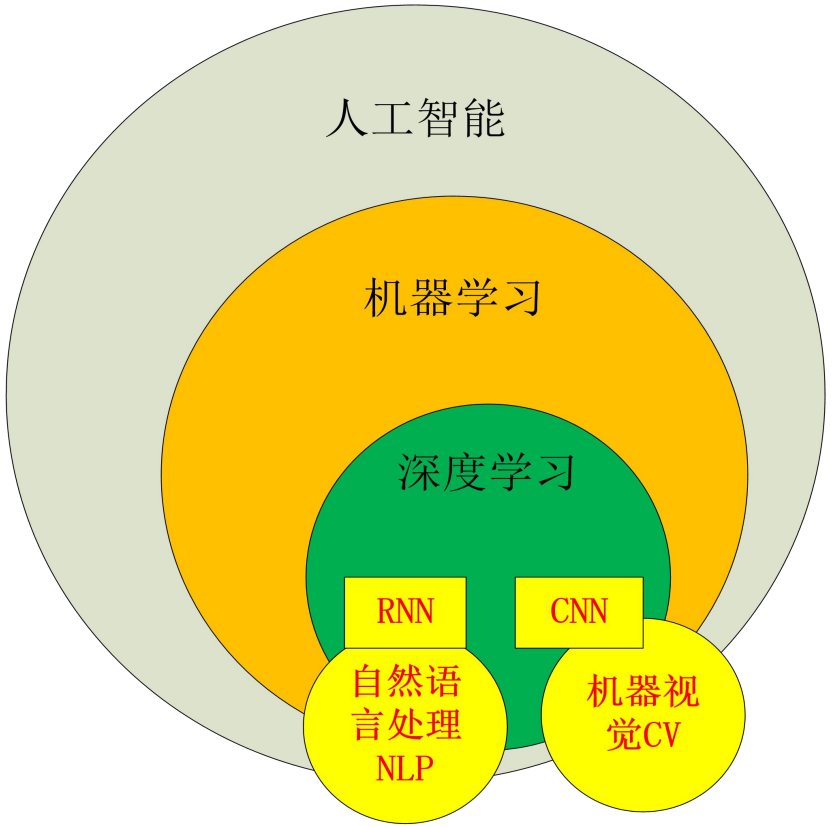
这个坐标系的轴方向就是主成分

目标：在新坐标系中实现数据的波动最大（方差最大）





深度学习概览

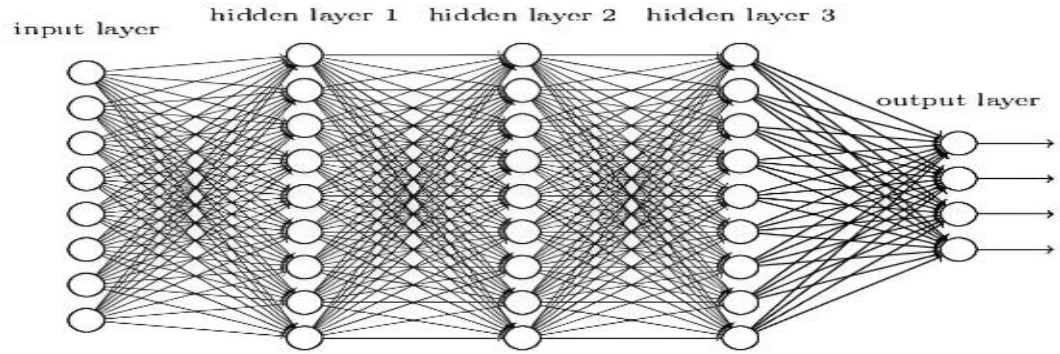


1、多层感知机（MLP）
2、卷积神经网络（CNN）
3、循环神经网络（RNN）
4、Transformer
5、扩散模型（Diffusion）

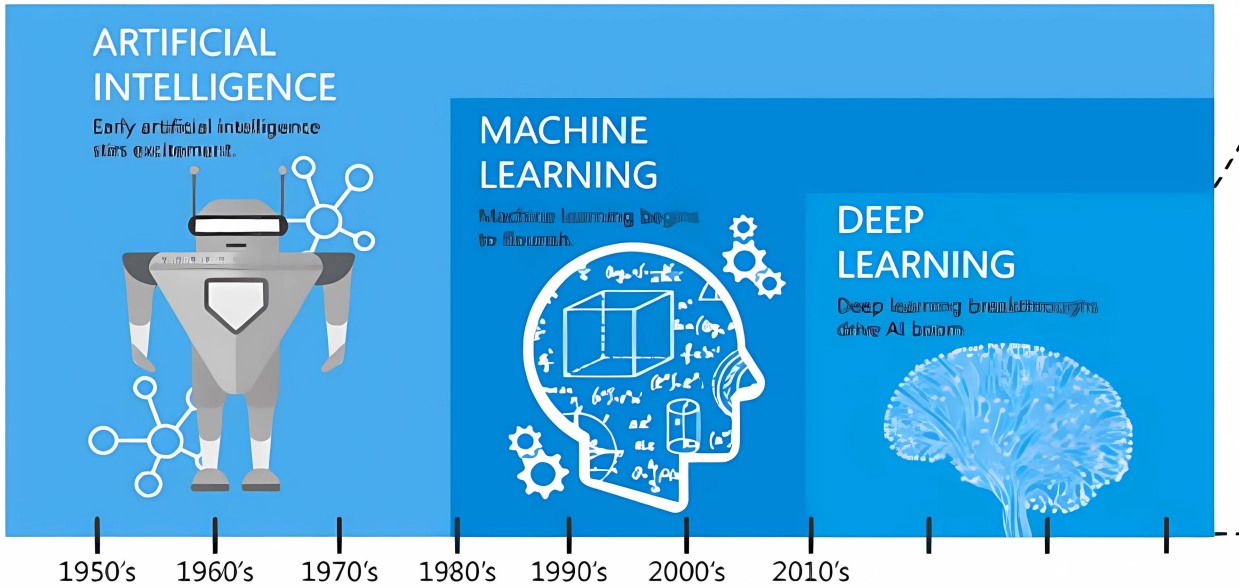
深度学习（Deep Learning，DL）是机器学习的一个子集，它使用**多层人工神经网络**来精准完成诸如物体检测、语音识别、语言翻译等任务。其基本思想是通过构建多层网络，对目标进行多层表示，以期通过**多层的高层次特征**来表示数据的抽象语义信息，从而获得更好的**特征鲁棒性**。

特征

多层网络结构：由多层神经元组成，包括输入层、隐藏层和输出层。这些层之间通过权重和偏置进行连接，形成复杂的网络结构。



自动特征提取：自动从原始数据中提取有用的特征，无需人工设计特征工程。
非线性激活函数：深度学习模型中通常使用非线性激活函数（如ReLU、sigmoid等），使得模型能够学习复杂的非线性关系。
大规模数据处理能力：借助现代计算技术和大数据资源，深度学习模型能够处理大规模数据集，提高模型的准确性和泛化能力。





机器学习属于人工智能（Artificial Intelligence）的一个方法子领域

计算机通过算法，利用经验（数据）来改善系统自身的性能

深度学习（Deep Learning）是一种实现机器学习的技术

利用深层神经网络，实现层级特征抽象和表示学习

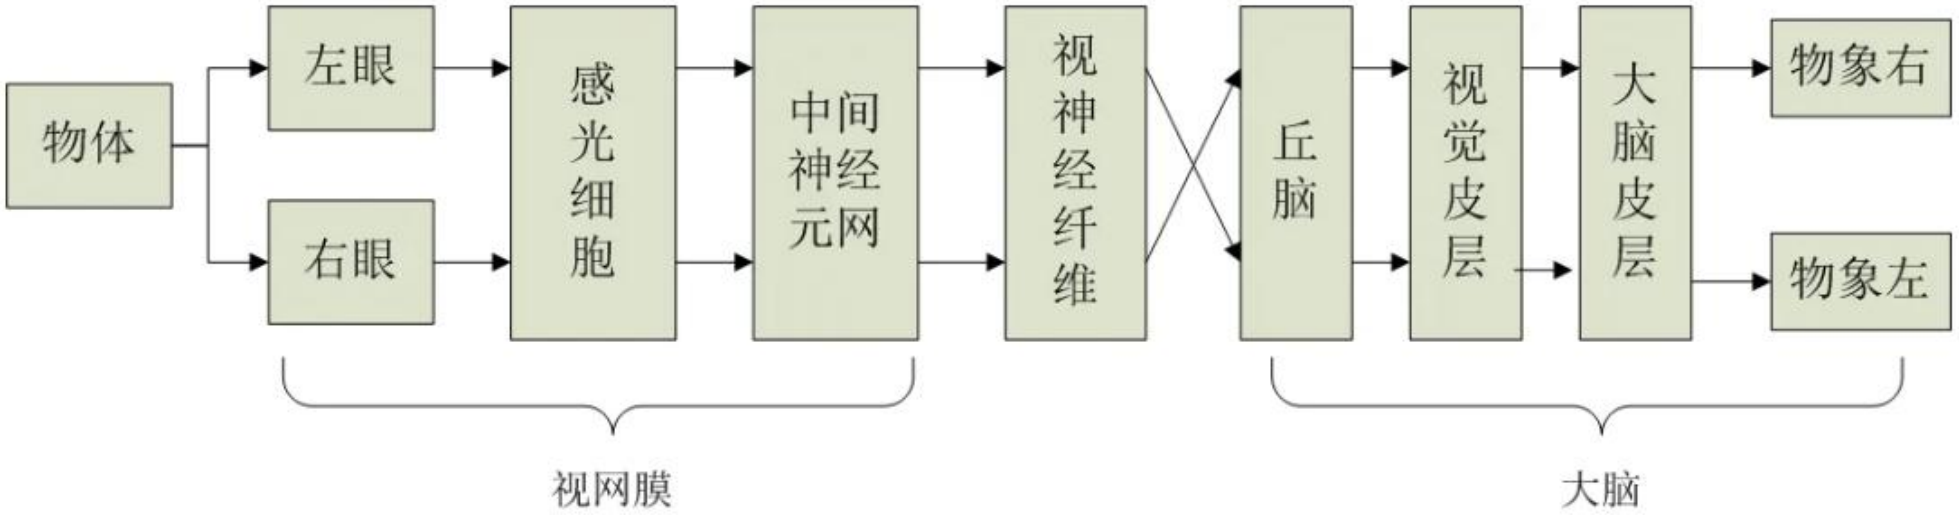
大模型（Foundation Model）参数规模在十亿以上的神经网络模型

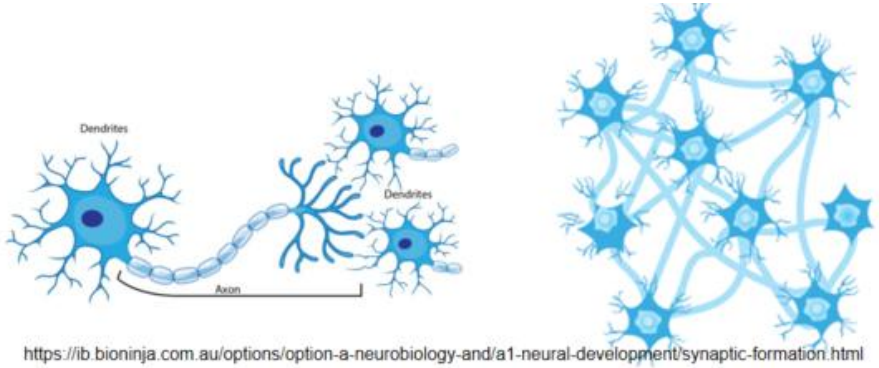
通常以Transformer作为基础结构，在海量无标注数据上进行自监督学习

大语言模型（Large Language Model）是一种具备对语言的理解和生成能力的大模型

基于Transformer的注意力机制，通过SFT激发后出现能力涌现

神经元特性及人眼识别物体过程

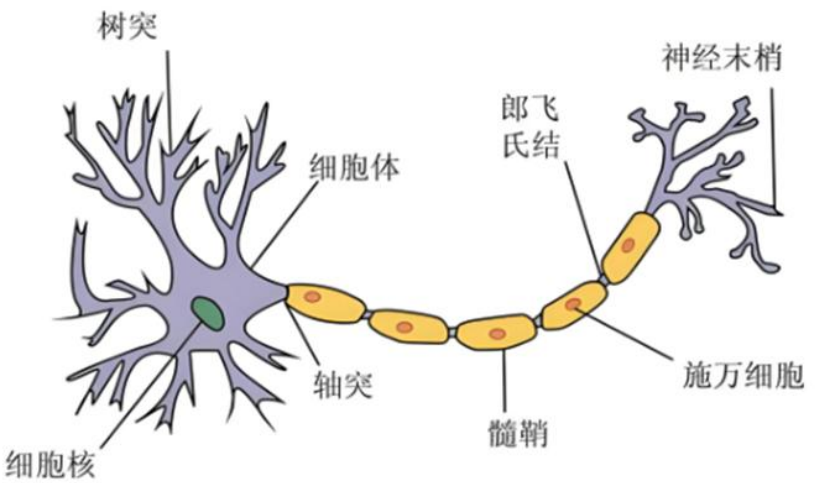


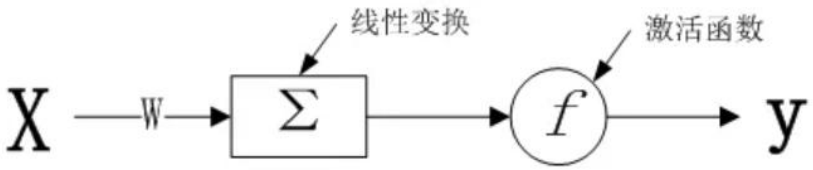


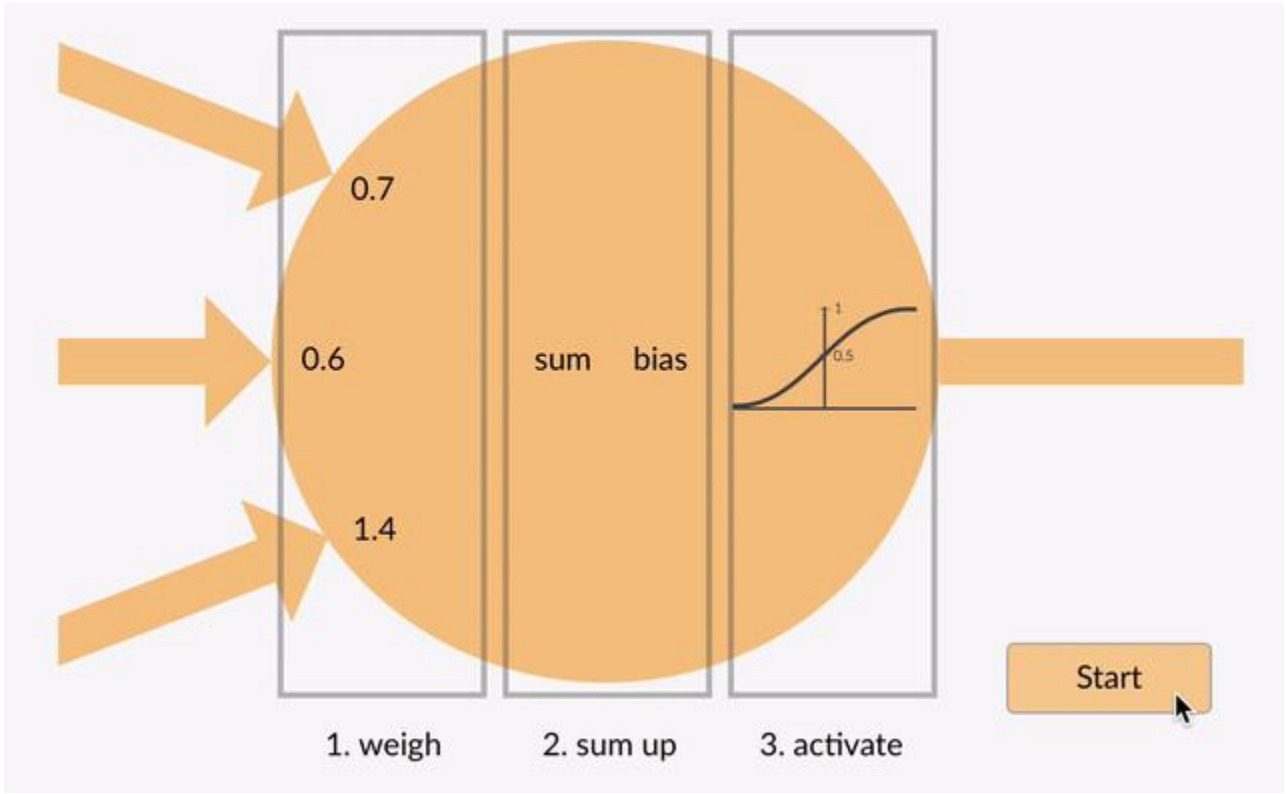
大脑是由约1千亿个神经元组成的，这些神经元都是同质的，而且功能很简单，但当大量神经元通过突触连接在一起时，就可以完成很复杂的功能。

神经元的**“全或无”现象**：只有当外来刺激有足够大的强度，才能引起神经元细胞的兴奋并产生动作电位，但再增加刺激强度并不会导致动作电位的幅度发生变化。神经元细胞产生的动作电位沿着细胞膜向周围传播，传播的范围和距离也不会随刺激强度的不同而不同。

感知机模型







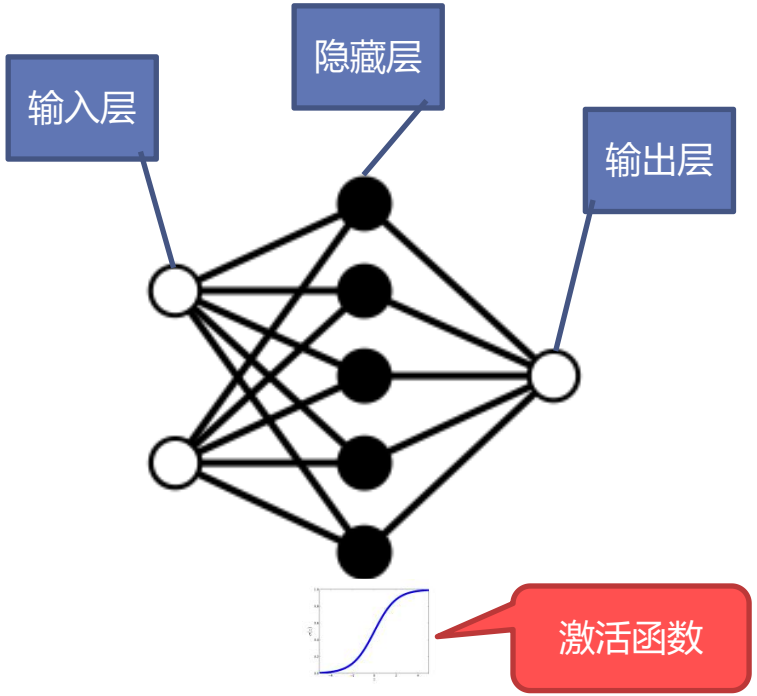
输入X可以是一个任意维度n的向量 $X = [x_i, x_2, ..., x_n]$ ，W是X的权重向量， $W = [w_1, w_2..., w_n]$,网络 $\sum = WX^T + b$ 完成线性变换。 f 是激活函数，完成非线性变换。

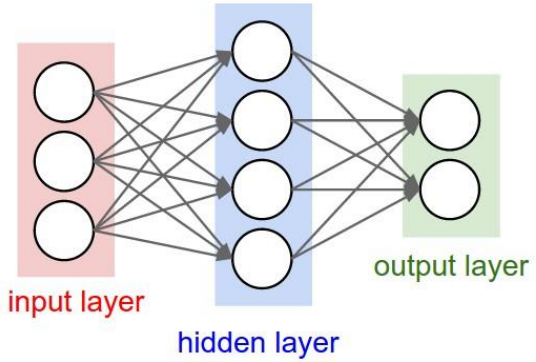
要求：根据图写出输出Y的公式（形式化表示）

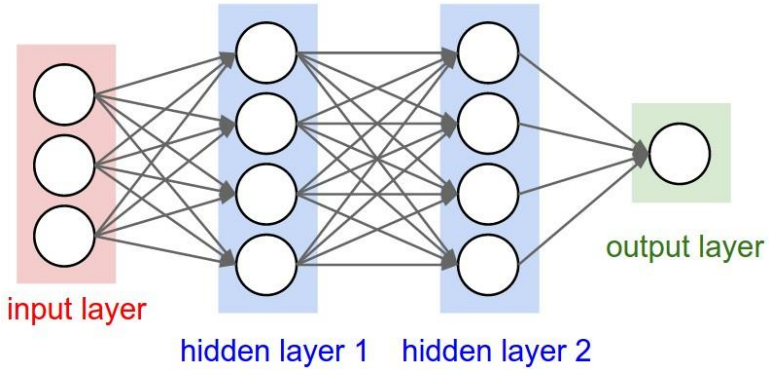
多层感知机MLP

多层感知机（MLP）

- 多层感知机是罗森布拉特标准感知器的扩展。如果以神经元来计算层数，一个多层感知器至少包含三层：一个输入层，一个隐藏层和一个输出层。
- 数据通过输入层进入网络，乘以连接的权重后输入到隐藏层节点。隐藏层节点将这些加权后的输入求和并经过一个非线性变换（称为激活函数）后送往输出层。







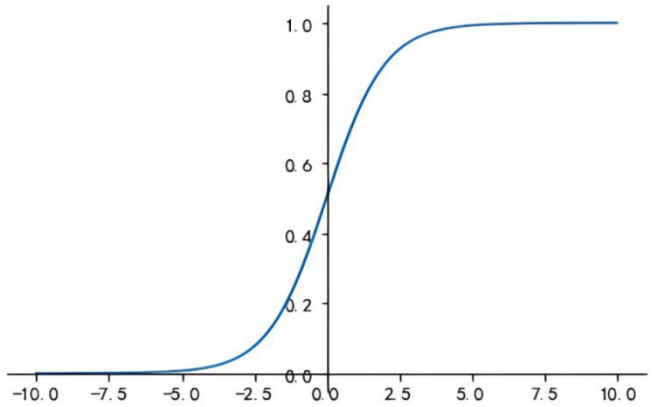
只有一个隐含层的叫浅层学习网络，隐含层大于一层的叫深度学习网络

激活函数



Sigmoid

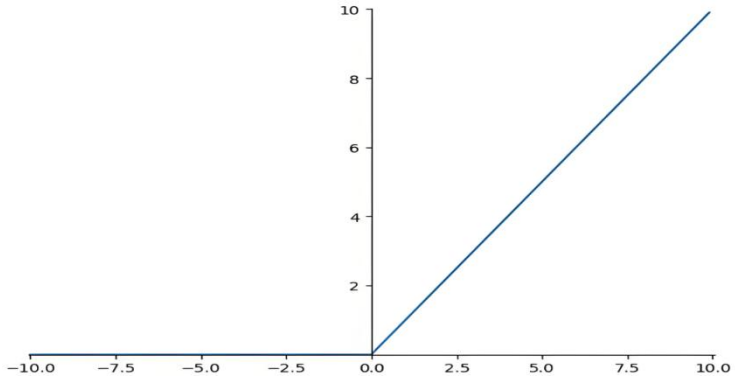
$$f(x) = \frac{1}{1+e^{-x}}$$



特性：
1）非线性
2）在-3与3之间，优化比较明显
3）在-3与3之外，优化不明显
4）值域在0~1之间，是非对称算法，这意味着下一个神经元只能接受正值的输入

ReLU

$$f(x) = max(0, x)$$



特性：
1）非线性
2）不会同时激活所有神经元
3）计算速度快
4）有趋于0的梯度
ReLU是目前隐含层中最为常用的损失函数

激活函数-Softmax



Softmax

$$S_i = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Softmax是将一个包含任意实数的K维向量压缩（或称为“归一化”）成另一个K维的实数向量，其中每一个元素的范围都在(0, 1)之间，并且所有元素的和为1。因此，Softmax的输出可以被解释为概率分布，其中每个概率对应着输入向量中对应元素属于某个类别的概率。

用途：应用最为广泛的一个激活函数分类器，一般用于最后一层，输出分类的概率结果，实现神经网络的分类，如：手写数字识别、物体分类、蛋白质结构分类、气象预测等应用

例 8-5：对于输入 $X = [2, 0.7, -1.5, -0.9]$，计算 Softmax 输出。

$$sum = \sum_j e^{x_j} = e^2 + e^{0.7} + e^{-1.5} + e^{-0.9} = 10.03$$

解：

$$S_1 = e^{x_1}/sum = e^2/10.03 = 0.74$$

$$S_2 = e^{x_2}/sum = e^{0.7}/10.03 = 0.20$$

$$S_3 = e^{x_3}/sum = e^{-1.5}/10.03 = 0.02$$

$$S_4 = e^{x_4}/sum = e^{-0.9}/10.03 = 0.04$$

23

误差反向传播算法-BP

- 反向传播算法是一种常见的人工神经网络学习算法，特别适用于多层前馈神经网络的训练。该算法由学习过程中的信号正向传播与误差的反向传播两个过程组成。

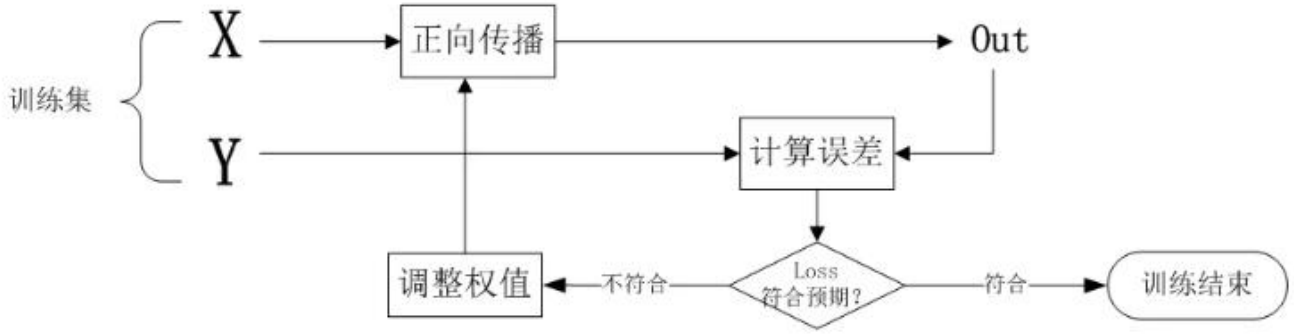
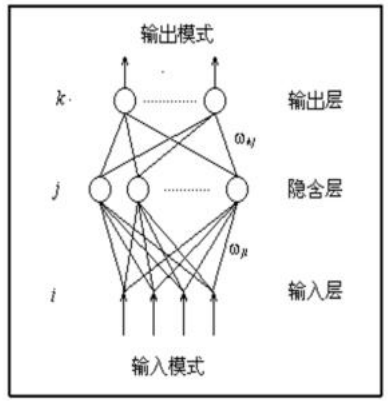


图　BP算法流程图

正向传播

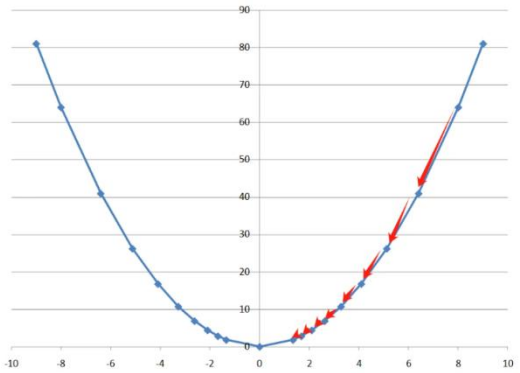


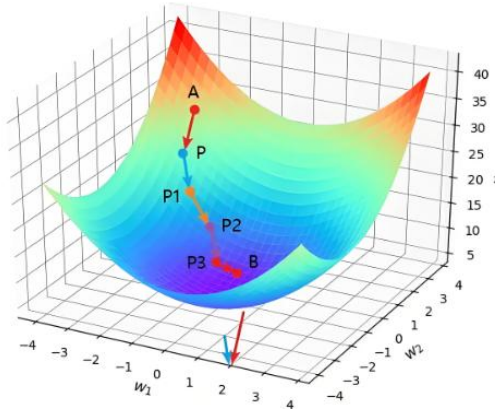
反向传播

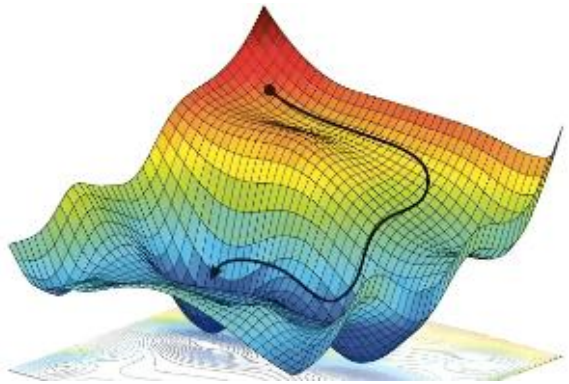
目标函数的输出值与期望输出不相符时，将输出误差以某种形式通过隐层向输入层逐层反传，在反传过程中，将误差分摊给各层的所有单元，获得各层单元的误差信号，算法根据这些误差值来调整连接权值，这种调整的目标是使得目标函数的输出值不断减小，直到达到设计预期

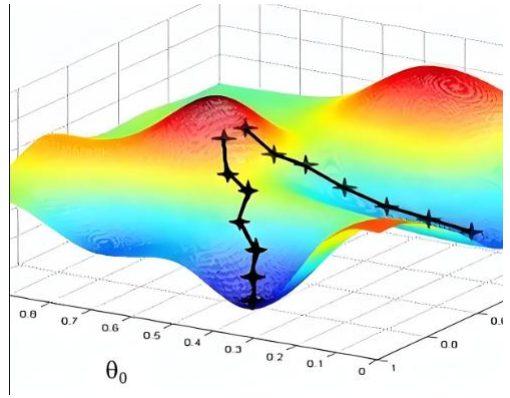
梯度下降

定义：以最快的速度找到函数局部最小值的优化算法









梯度 ∇ ：函数在某点变化最快的方向
一元方程：某点的斜率（导数）；
多元方程：函数所有变量在某处偏导数的向量。

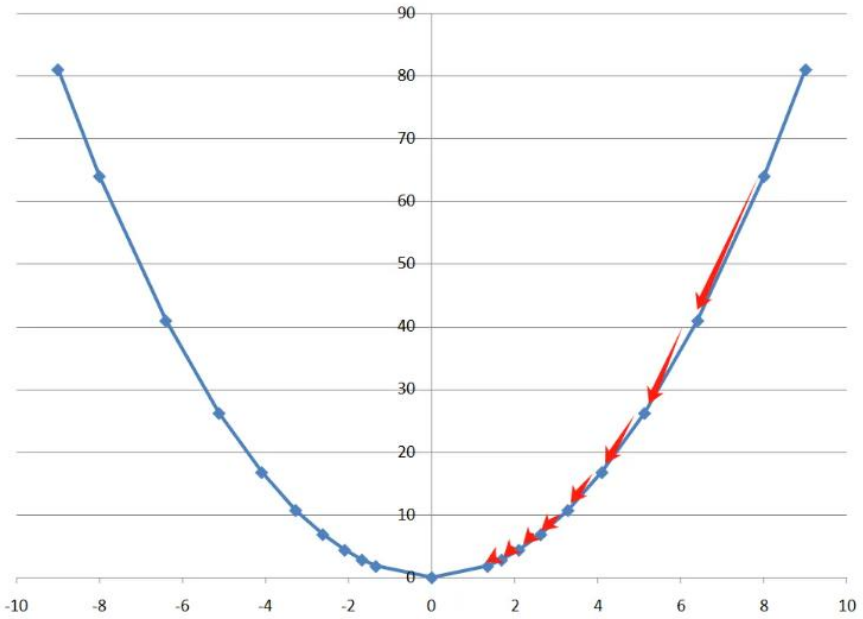
$$gradf(x,y,z) = \nabla f(x,y,z) = [\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}]$$

最小值寻找过程：（1）方向的选择-梯度 （2）前进的步长-学习率 （3）何时终止 - 梯度≈0

如何应用：设计损失函数，沿着损失函数梯度的反方向更新网络参数

图片来源：百度

梯度下降案例



$f(x) = x^2$ ： 起点P(8,64)，学习率=0.1，

x_i	8	6.4	5.12	4.096	3.277	2.622	2.098	1.679	1.343
∇f	16	12.8	10.24	8.192	6.554	5.244	4.196	3.358	……
$x_i - \eta \nabla f$	6.4	5.12	4.096	3.277	2.622	2.098	1.679	1.343	……

练一练：学习率=0.2时，上述曲线梯度下降算法的过程，并画图（手工计算）

练一练：用python实现一个梯度下降算法的函数，参数为终止条件、学习率、起点

26

BP算法特性



BP算法的特点

（1）自适应、自主学习：BP算法能够根据预设的参数更新规则，不断地调整神经网络中的参数，以达到最符合期望的输出。

（2）较强的非线性映射能力：由于神经网络中的激活函数都是非线性的，因此BP算法能够处理复杂的非线性问题。

（3）严谨的推导过程：误差的反向传播过程采用的是已经非常成熟的链式法则，其推导过程严谨且科学。

（4）较强的泛化能力：在训练结束后，BP算法可以利用从训练数据中学到的知识解决新的问题。

BP算法的局限性

（1）易陷入局部最小值：由于BP算法采用的是梯度下降法，容易陷入局部极小值而得不到全局最优解。

（2）收敛速度慢：由于神经网络中的参数众多，每次迭代都需要更新大量的权值和阈值，导致收敛速度较慢。

（3）隐节点选取缺乏理论指导：传统方法需要不断地设置隐含层节点数进行试凑，以确定最优的隐含层结构。

（4）学习新样本时可能遗忘旧样本：在训练过程中，学习新样本时可能会遗忘之前已经学习过的旧样本。

优化器-梯度下降的优化



随机梯度下降法　Stochastic Gradient Descent, SGD

一次计算全部样本的误差之和→一次只计算一个（批）样本

优点：1 高效
　　2 可并行计算
　　3 可适应新数据变化（预训练思想萌芽）
　　4 有机会全局最优

局限：1不稳定
　　2 没有解决学习率选择问题
　　3 随机最优解
　　4 模型不可控

改进：**小批量梯度下降法（Mini-batch SGD）**
　　动量梯度下降法（Momentum SGD）-梯度移动平均

Python 实现

optimizer = optim.SGD(model.parameters(), lr=0.01)
optimizer = optim.SGD(model.parameters, momentum=0.9)

自适应梯度算法 Adaptive Gradient,，AdaGrad

根据权重的梯度自适应调整学习率，分母增加历史梯度累积值

优点：1 自动化调整学习率
　　2 自适应，所有权重“步调一致”

局限：1 梯度消失（训练次数作为分母）
　　2 训练速度慢

改进：**自适应平方根梯度法（RMSProp）**
　　自适应矩估计法（Adam） 目前最常用

Python 实现

optimizer =optim.Adagrad(model.parameters(), lr=0.01,weight_decay=1e-4, eps=1e-10)

optimizer = optim.Adam(model.parameters(), lr=0.01,betas=(0.9, 0.999),eps=1e-8, weight_decay=0)

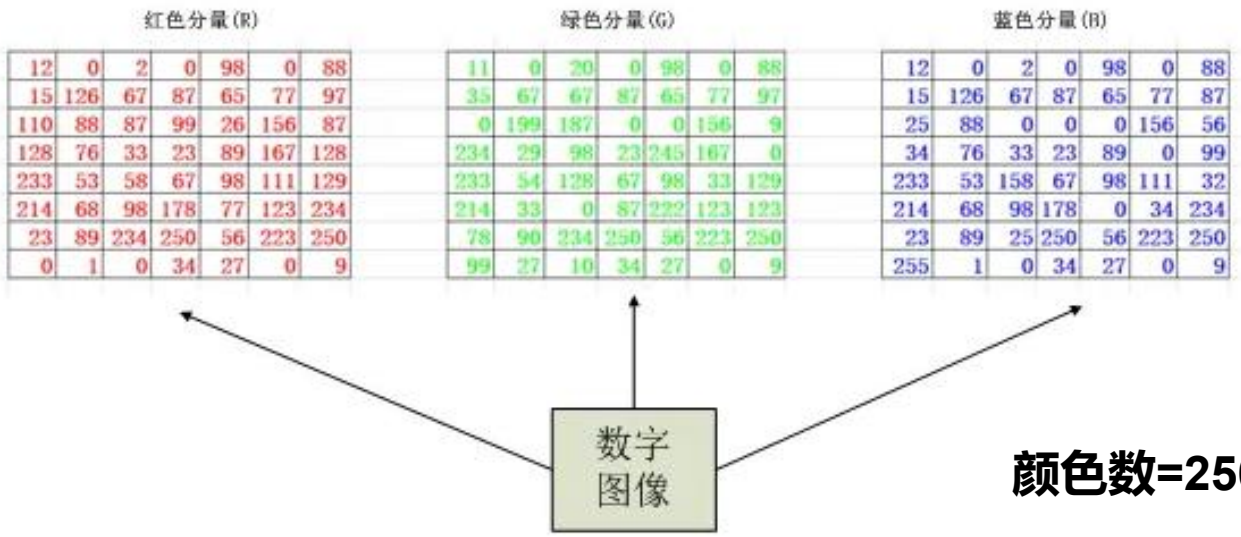
28

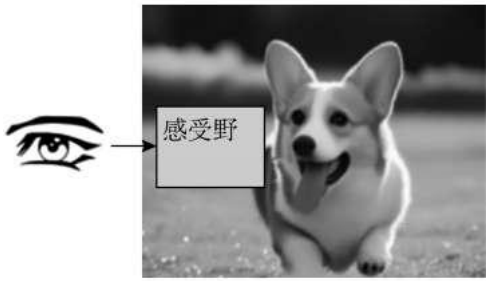
图像的数字化表示、感受野



图像的数字化表示

现实物理世界的图像不能被直接用于计算处理，必须先经过数字化处理，如扫描仪、数字相机等。为了对数字图像进行统一规范，人为的将数字图像用RGB三原色（红、绿、蓝）通道来表示，每种颜色的强度用一个字节表示，取值范围0~255。比如一个彩色数字化图像的分辨率是8×7，其可表示成如下的数字方式：

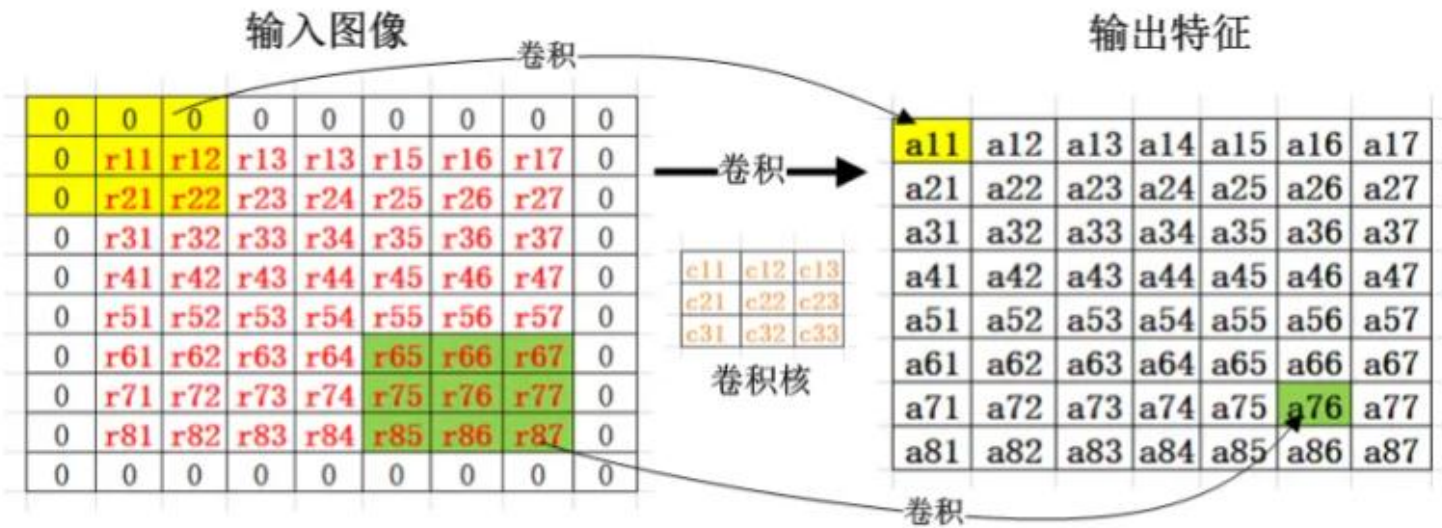


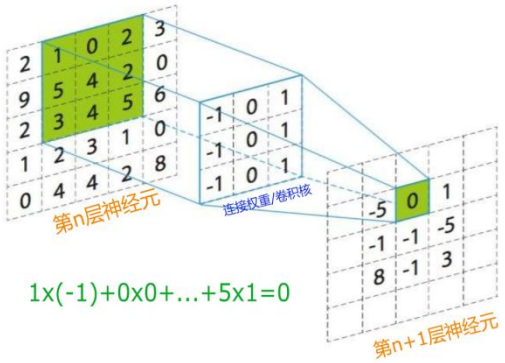


颜色数=256*256*256=16777216

卷积运算

卷积运算：卷积运算就是通过设计一系列大小适中的卷积核（感受野），对数字图像的各个通道分量（二维矩阵）进行卷积，提取特征值的过程。常用的卷积核大小为3×3、5×5、7×7。





a11 = 0×**c11** + 0×**c12** + 0×**c13** +
0×**c21** + r11×**c22** + r12×**c23** +
0×**c31** + r21×**c32** + r22×**c33**

a12 = 0×**c11** + 0×**c12** + 0×**c13** +
r11×**c21** + r12×**c22** + r13×**c23** +
r21×**c31** + r22×**c32** + r23×**c33**

...

...

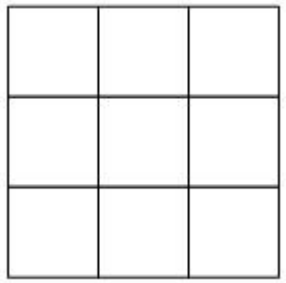
a76 = r65×**c11** + r66×**c12** + r67×**c13** +
r75×**c21** + r76×**c22** + r77×**c23** +
r85×**c31** + r86×**c32** + r87×**c33**

...

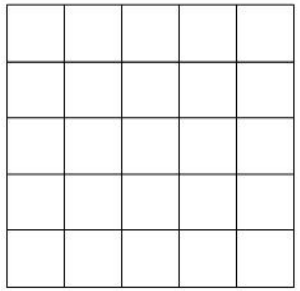
a87 = r76×**c11** + r77×**c12** + 0×**c13** +
r86×**c21** + r87×**c22** + 0×**c23** +
0×**c31** + 0×**c32** + 0×**c33**

卷积运算中的三个主要参数

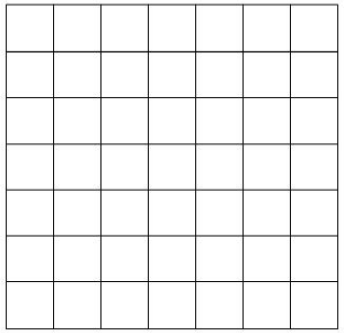
1 卷积核形状：



3×3

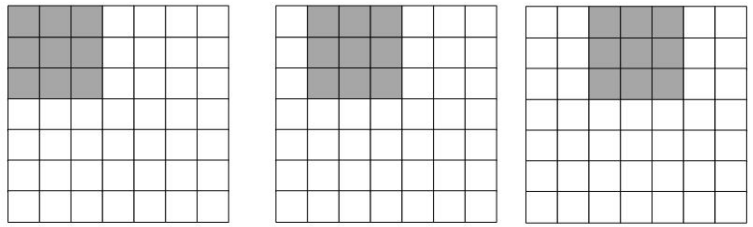


5×5

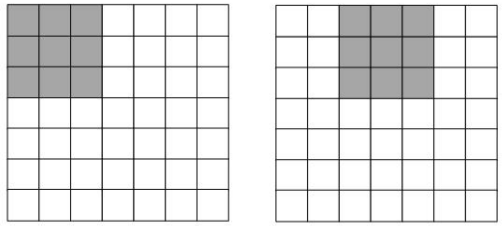


7×7

2 步长：决定运算的速度



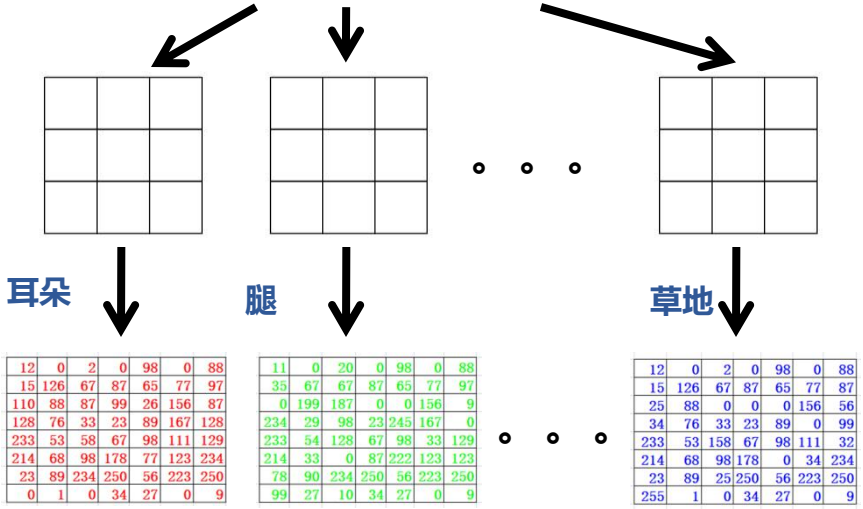
步长=1



步长=2

3 卷积核数量:决定每一层能提取的特征数





池化

池化（pooling）：池化也称下采样，其作用就是缩小特征图的尺寸，减少计算量。池化的原理是可以用某一图像区域子块的统计信息包含了该子块全局信息。池化操作主要有最大池化、平均池化、随机池化、L2范数池化、K-max池化和全局平均池化等。CNN常用2×2区域进行池化。

例9-2：对如下的特征图进行平均池化计算，池化窗口2×2，

最大池化	池化结果	随机池化	池化结果
125 115 137 120	137	12 11 17 10	Radom(12,11,17,10)
平均池化	**池化结果**	**L2范数池化**	**池化结果**
33 46 57 40	44	19 15 26 23	$\sqrt{19^2+15^2+26^2+23^2}$

23	34	55	32	66	43
15	43	27	30	39	54
33	67	47	28	36	49
56	89	90	35	77	65
54	32	37	48	65	32
63	67	38	43	29	54

步长=2

A1=(23+34+15+43)/ 4=28.75	A2=(55+32+27+30)/ 4=36	A3=(66+43+39+54)/ 4=50.5
A4=(33+67+56+89)/ 4=61.25	A5=(47+28+90+35)/ 4=50	A6=(36+49+77+65)/ 4=56.75
A7=(54+32+63+67)/ 4=54	A8=(37+48+38+43)/ 4=41.5	A9=(65+32+29+54)/ 4=45

32

CNN的本质

独热码（One-Hot code）：在分类问题中，我们不能将不同的分类用1,2,3，……这种有序的数字来表示，只能通过**独热码**这样的向量矩阵来进行编码，供计算机识别计算，并用所在索引位置的概率值来预测最终的分类结果

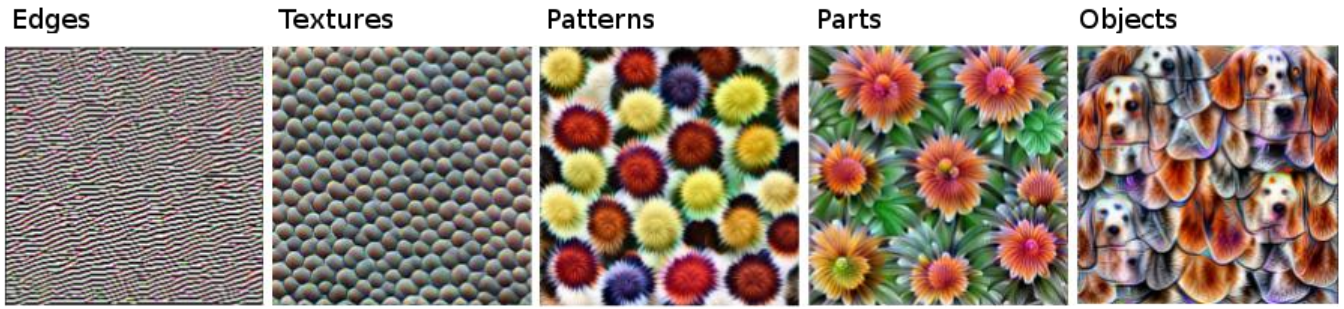
	猫	狗	猪	牛	羊
猫	1	0	0	0	0
狗	0	1	0	0	0

独热码-编码

	猫	狗	猪	牛	羊	求和
猫	0.76	0.18	0.03	0.02	0.01	1
狗	0.05	0.92	0.01	0.01	0.01	1

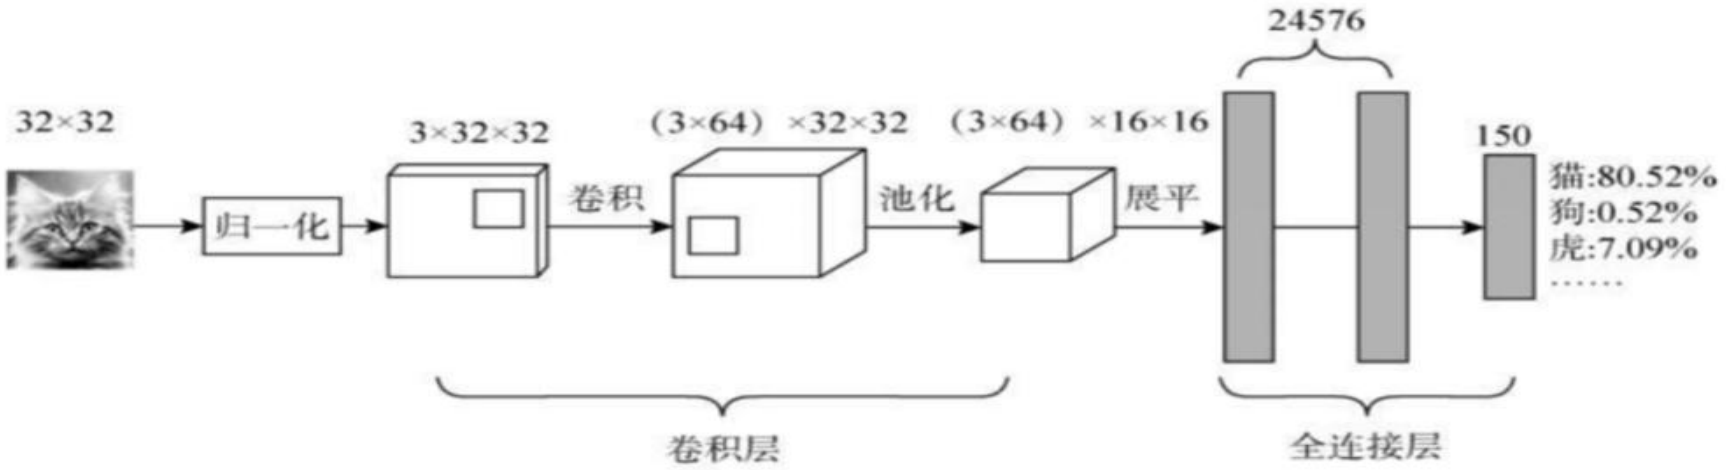
前馈网络运算结果

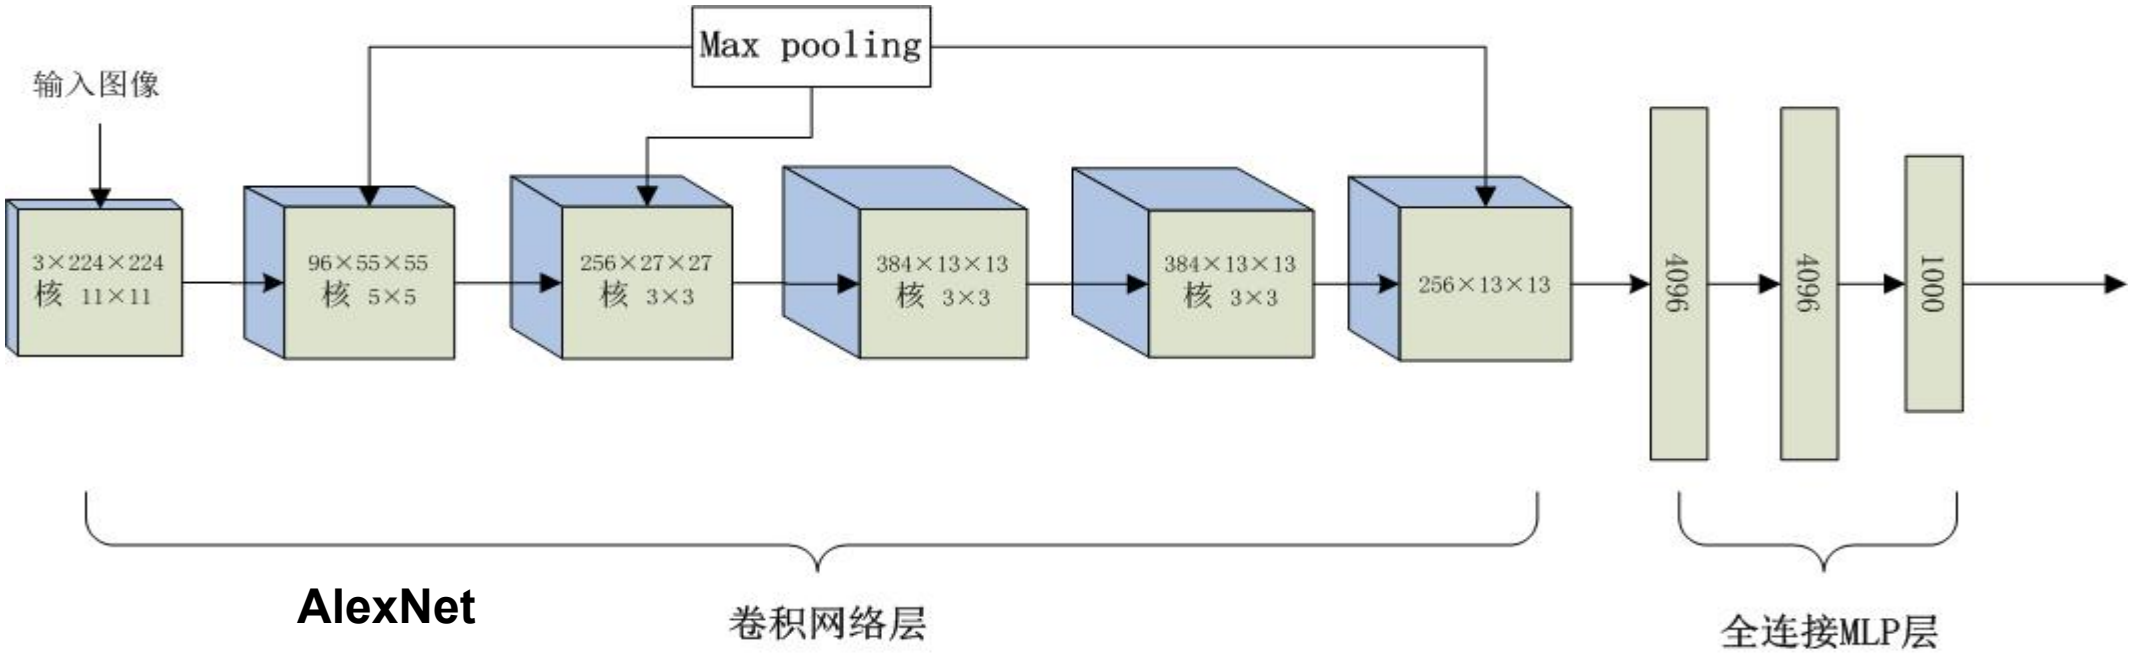
层次特征学习：深度神经网络之所以如此强大，一个很重要的原因在于它可以通过层次性处理逐渐提取抽象特征



随着层次的深入，低级特征逐渐向高级特征进化

CNN的拓扑结构


32×32
归一化
3×32×32
卷积
(3×64) ×32×32
池化
(3×64) ×16×16
展平
24576
150
猫:80.52%
狗:0.52%
虎:7.09%
.....
卷积层
全连接层

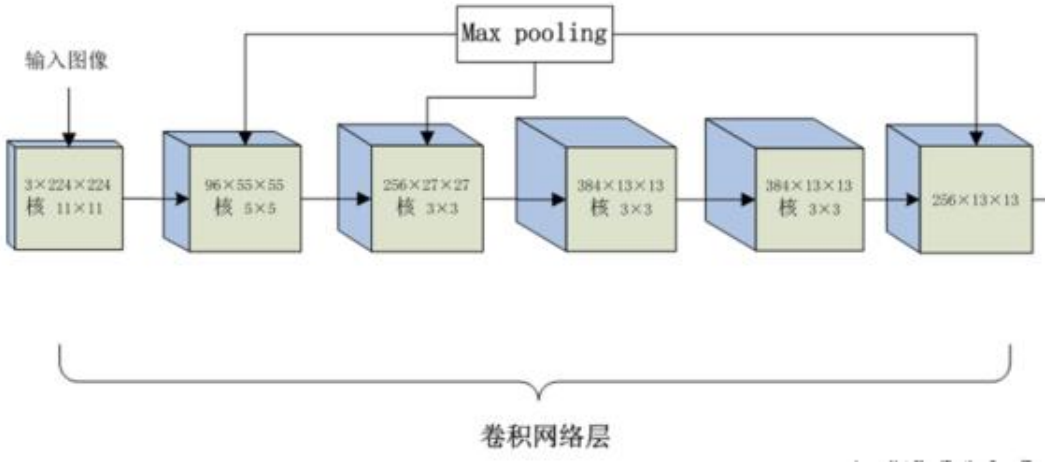

Max pooling
输入图像
3×224×224
核 11×11
96×55×55
核 5×5
256×27×27
核 3×3
384×13×13
核 3×3
384×13×13
核 3×3
256×13×13
4096
4096
1000
AlexNet
卷积网络层
全连接MLP层

AlexNet



第一部分：以下为卷积网络层						
层数	算法	kernels	kernel_size	padding	stride	output_size
1	卷积	96	11×11	[1,2]	4	[55,55,96]
	激活函数	ReLU				
	最大池化		3×3	0	2	[27,27,96]
2	卷积	256	5×5	[2,2]	1	[27,27,256]
	激活函数	ReLU				
	最大池化		3×3	0	2	[13,13,256]
3	卷积	384	3	[1,1]	1	[13,13,384]
	激活函数	ReLU				
4	卷积	384	3	[1,1]	1	[13,13,384]
	激活函数	ReLU				
5	卷积	256	3	[1,1]	1	[13,13,256]
	激活函数	ReLU				
	最大池化		3×3	0	2	[6,6,256]

卷积运算后的形状?



例9-2：对如下的特征图进行平均池化计算，池化窗口2×2，

23	34	55	32	66	43
15	43	27	30	39	54
33	67	47	28	36	49
56	89	90	35	77	65
54	32	37	48	65	32
63	67	38	43	29	54

步长=2的池化

三种神经网络

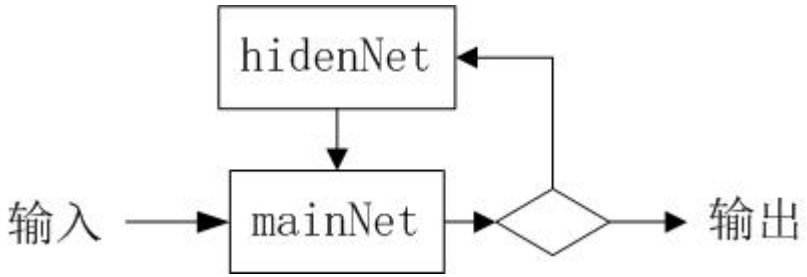
前馈神经网络



多层感知机 MLP

卷积神经网络 CNN

反馈神经网络



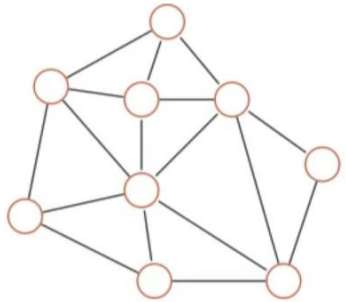
循环神经网络 RNN

长短程记忆网络 LSTM

Hopfield网络

波尔兹曼机

图网络



知识图谱

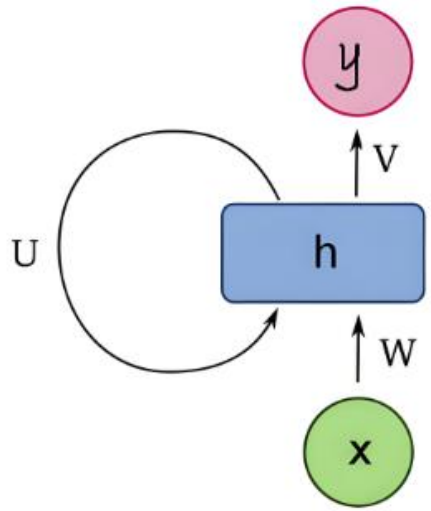
社交网络

城市交通

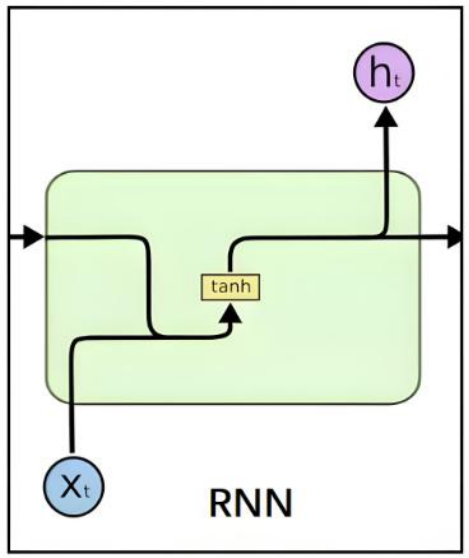
36

RNN的结构

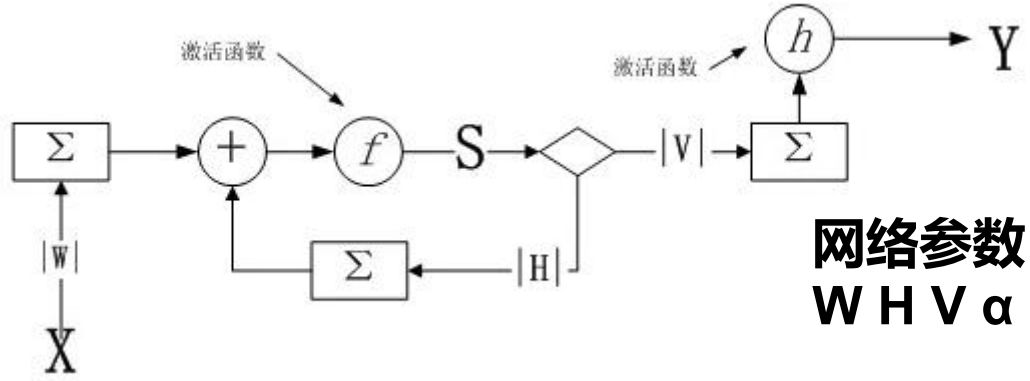
循环神经网络（Recurrent Neural Network，RNN）：是一种特殊类型的反馈神经网络，专门用于处理序列数据。RNN的核心思想在于其循环结构，使得网络能够捕捉和利用序列中的顺序依赖性信息。RNN的基本单元是一个具有循环连接的神经网络层。这个循环连接允许网络在处理每个时间步的数据时，能够利用之前时间步的信息。具体来说，RNN在每个时间步都会接收一个输入，并产生一个输出，同时其内部状态（隐藏状态）会被更新并传递到下一个时间步。



表示法一



表示法二



网络参数：
W H V α β

t时刻的输出：

$$Y_t = h(V \bullet S_t + \alpha)$$

$$S_t = f(W \bullet X_t + H \bullet S_{t-1} + \beta)$$

表示法三

RNN按序列展开

预测：“天行健，君子以自强不（）”

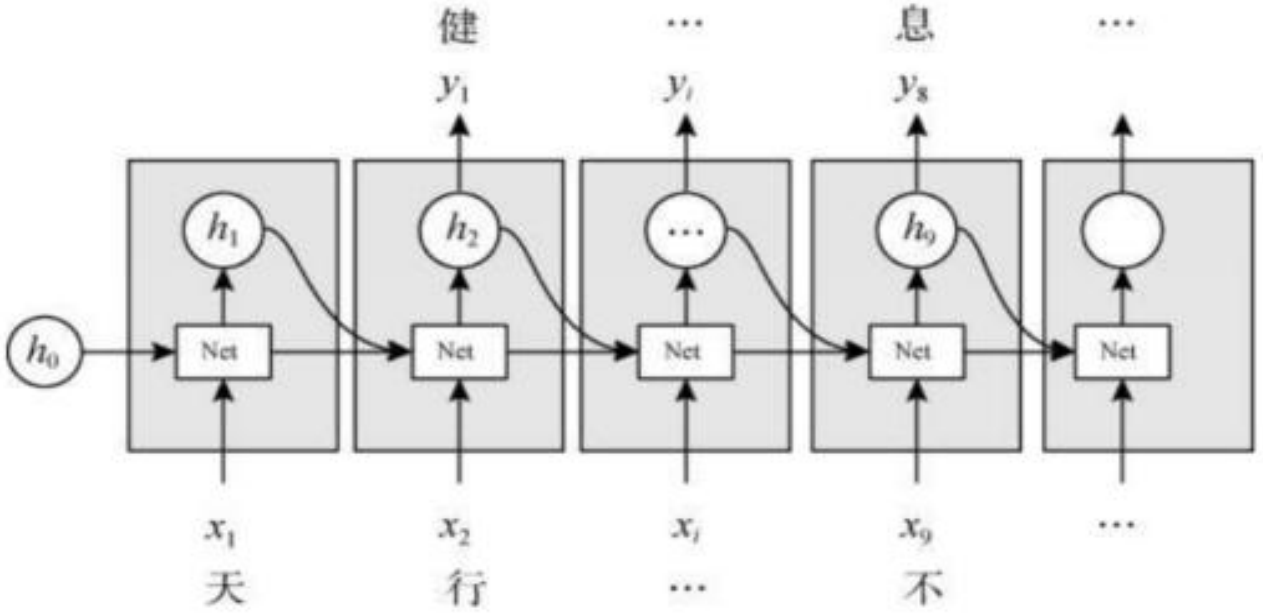


图 9-3　RNN按序列展开实例

数据集的构建

$i=$	1	2	3	4	5	6	7	8	9
x_i	天	行	健	君	子	以	自	强	不
y_i	健	君	子	以	自	强	不	息	

⟶词向量

⟶词向量

RNN计算例题

例10-1：已知拓扑结构为同步多对多RNN（基本结构见图 RNN基本逻辑结构），输入层、隐含层（一层）、输出层的神经元均为一个，激活函数均为ReLU，$W=[0.5,0.1,0.2]$，$H=[1]$，$V=[3]$，$S_0=0$，$\alpha=0$，$\beta=0$，对 X =[[1,1,1]，[2,2,2]，[3,3,3]] 的输入序列，计算其输出序列 Y 。

解： $X_1=[1,1,1]$ $X_2=[2,2,2]$ $X_3=[3,3,3]$

$$S_1=f(W\bullet X_1^T+H\bullet S_0)=f(0.8)=0.8$$

$$Y_1=h(V\bullet S_1)=h(2.4)=2.4$$

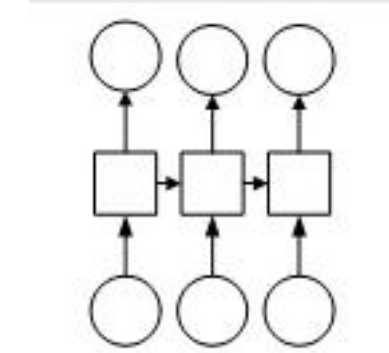
$$S_2=f(W\bullet X_2^T+H\bullet S_1)=f(1.6+0.8)=2.4$$

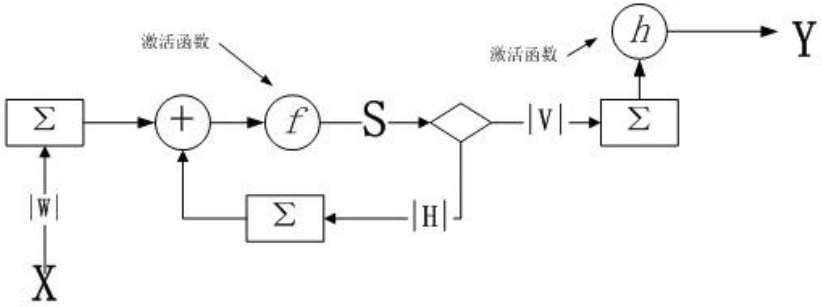
$$Y_2=h(V\bullet S_2)=h(7.2)=7.2$$

$$S_3=f(W\bullet X_3^T+H\bullet S_2)=f(2.4+2.4)=4.8$$

$$Y_3=h(V\bullet S_3)=h(7.2)=14.4$$

$$\therefore Y=[2.4,7.2,14.4]$$

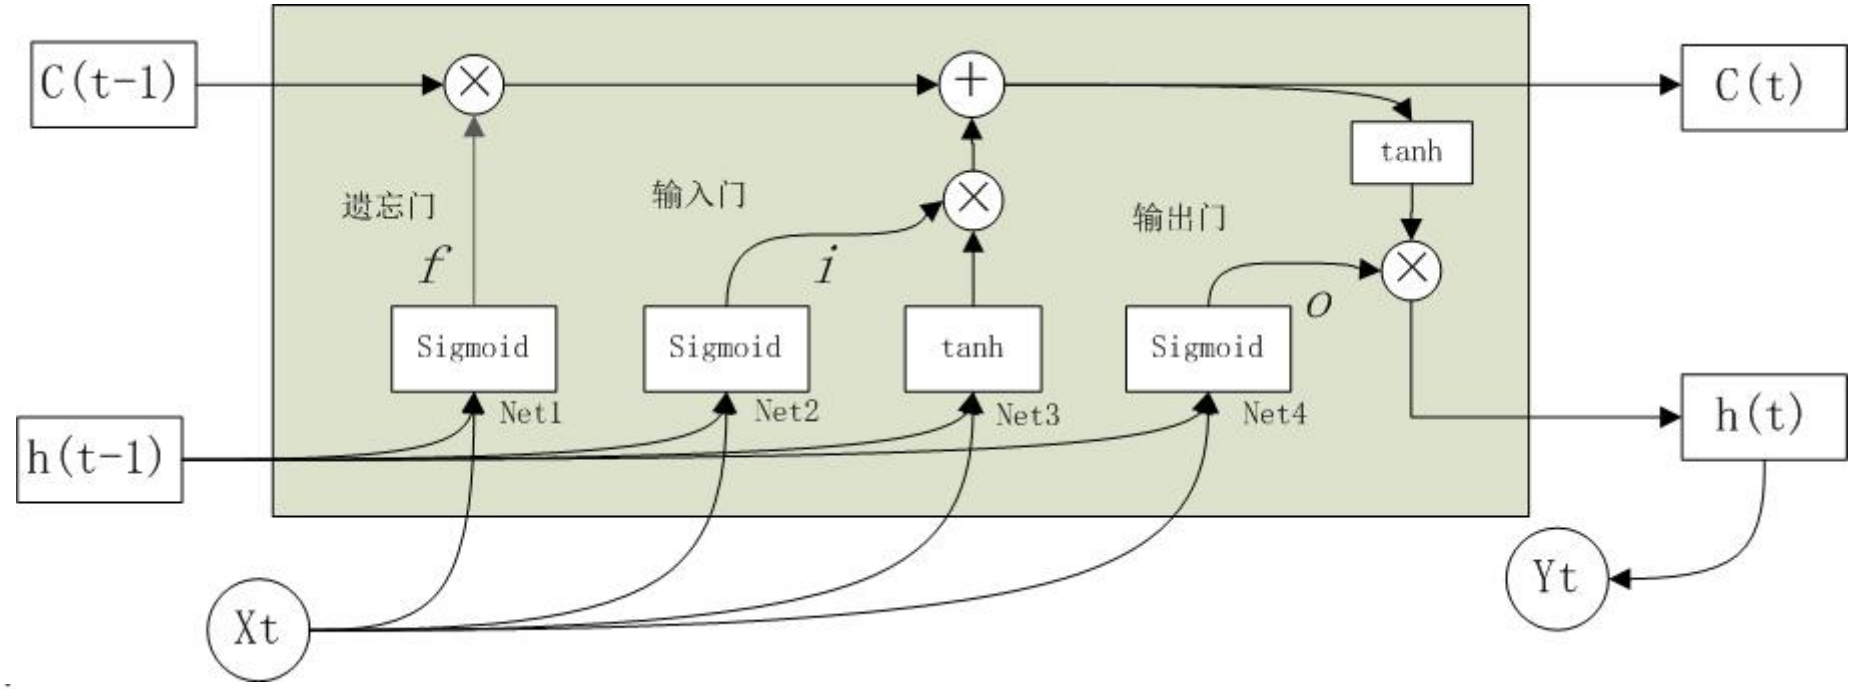




$$Y_t=h(V\bullet S_t+\alpha)$$

$$S_t=f(W\bullet X_t+H\bullet S_{t-1}+\beta)$$

LSTM的算法过程



网络参数：

$W_{h(1-4)}$

$W_{x(1-4)}$

b_{1-4}

	作用	计算方法
遗忘门	决定什么时候把以前的状态遗忘	f_t =sigmoid（Net1）
输入门	决定什么时候加入新的状态	i_t =sigmoid（Net2）
输出门	决定什么时候把状态和输入叠加输出	o_t =sigmoid（Net4）
记忆状态	累积历史信息，调控h_t输出内容	$C_t = f_t \otimes C_{t-1} + i_t \otimes$ tanh(Net3)
隐式编码	与下一次的输入一起参与计算	$h_t = o_t \otimes \tanh(C_t)$

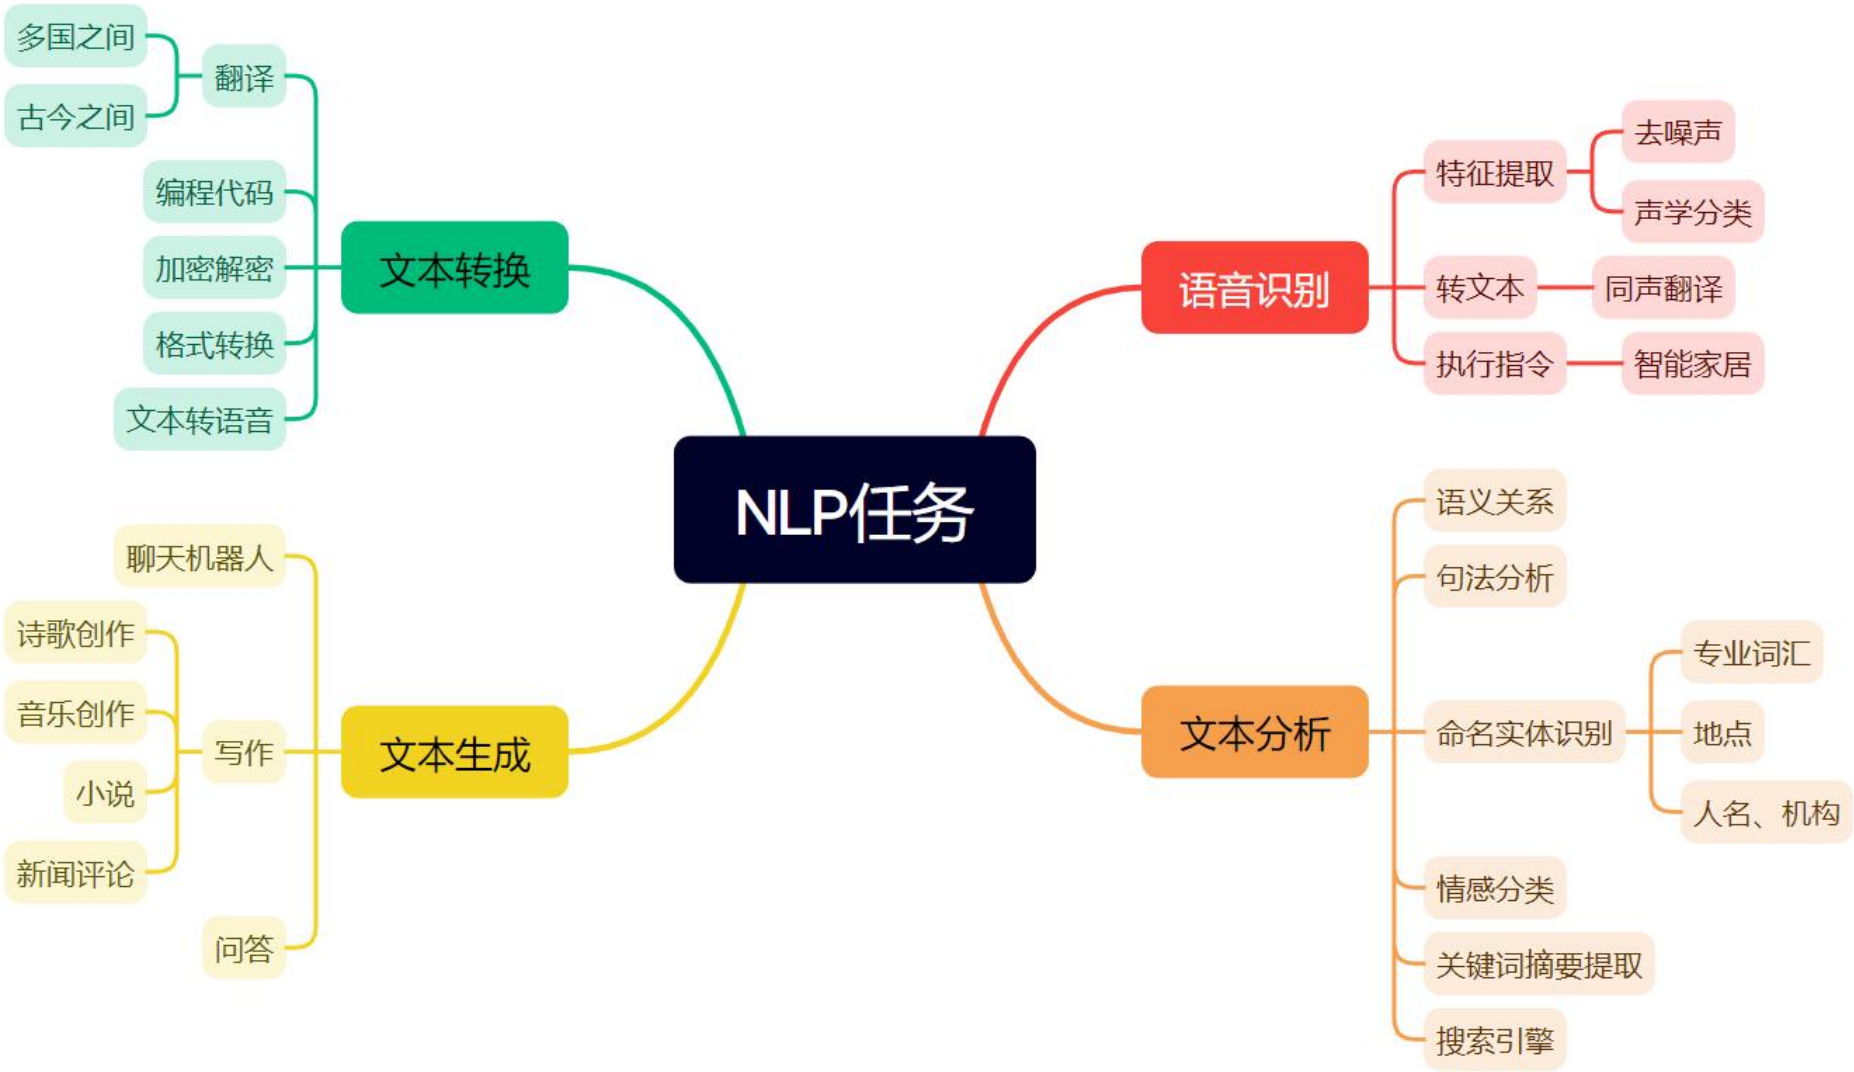
$$Net1 = W_{h1} \cdot h_{t-1} + W_{x1} \cdot X_t + b_1$$

$$Net2 = W_{h2} \cdot h_{t-1} + W_{x2} \cdot X_t + b_2$$

$$Net3 = W_{h3} \cdot h_{t-1} + W_{x3} \cdot X_t + b_3$$

$$Net4 = W_{h4} \cdot h_{t-1} + W_{x4} \cdot X_t + b_4$$

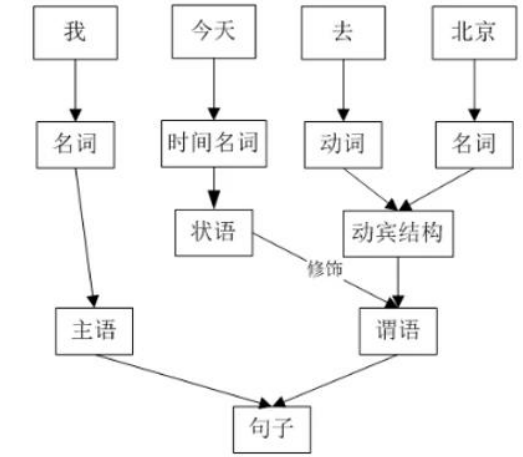
NLP任务分类

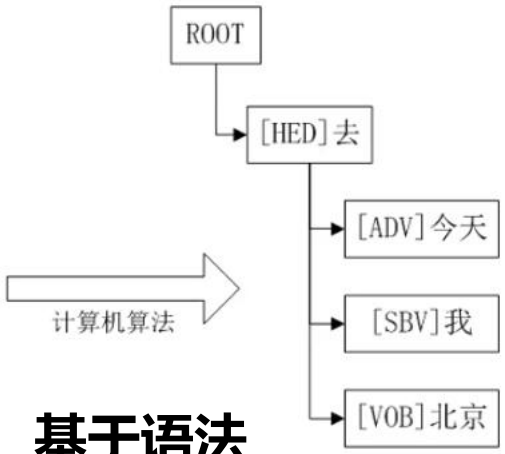

NLP任务
文本转换
翻译
多国之间
古今之间
编程代码
加密解密
格式转换
文本转语音
文本生成
聊天机器人
写作
诗歌创作
音乐创作
小说
新闻评论
问答
语音识别
特征提取
去噪声
声学分类
转文本
同声翻译
执行指令
智能家居
文本分析
语义关系
句法分析
命名实体识别
专业词汇
地点
人名、机构
情感分类
关键词摘要提取
搜索引擎

41

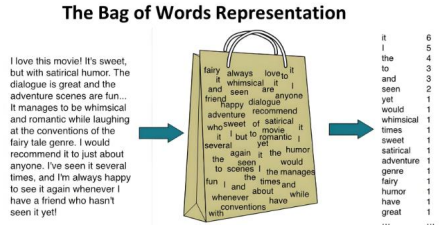
NLP技术演变

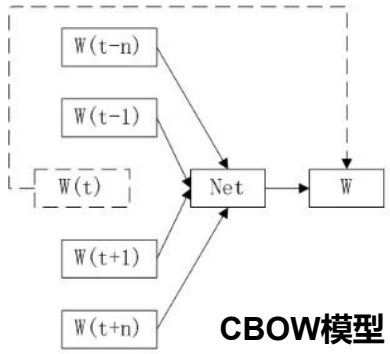
基于规则算法 → 统计语言模型 → 序列生成模型 → 预训练-微调模型



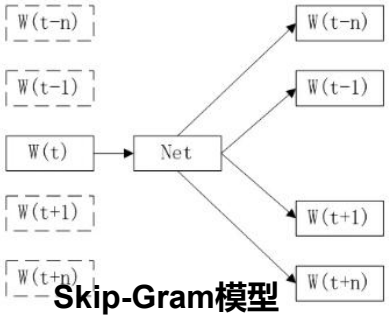


基于语法

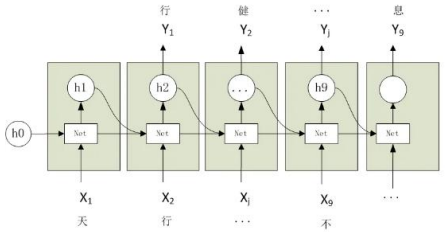




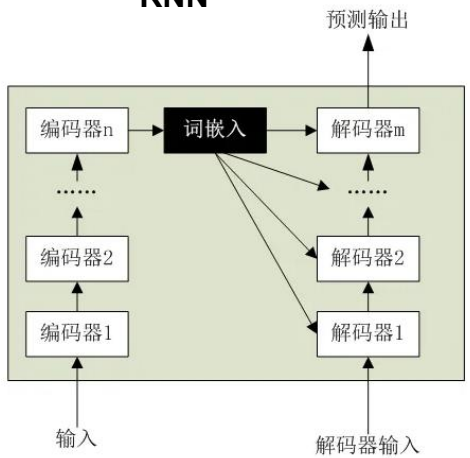
CBOW模型



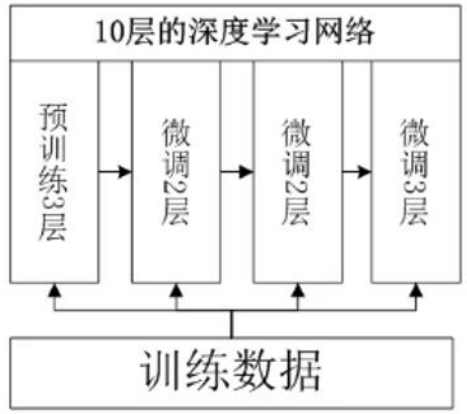
Skip-Gram模型



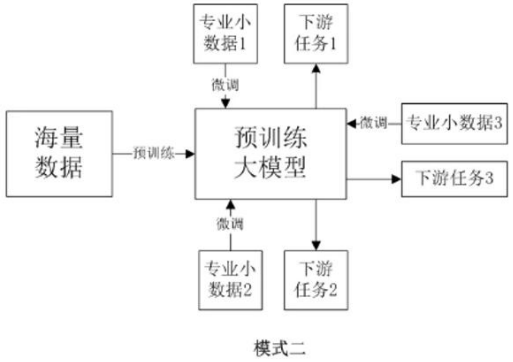
RNN



Transformer



模式一



模式二

分词



Token：令牌，可以是一个字，也可以是一个词，或者是一个字母，甚至是一个字节，要看具体的情况。本质上，一个“Token”就是通过分词技术（工具）将一句话分割成的最小单位，是一个特定的自然语言处理模型能处理的最基本元素，至小有内，至大无外。

“黄山落叶松叶落山黄”

按字分 “黄-山-落-叶-松-叶-落-山-黄” 词汇表5个token，句子9个token

按词分 “黄山-落叶松-叶-落-山-黄” 词汇表6个token，句子6个token

“I like to read this book about books that I like“
如何分词?

分词需在词汇表大小和语料大小之间取得平衡，也是模型成败最关键一步。
开源模型都自带分词工具和词汇表

词向量和词嵌入



词向量就是词的特征分布，是NLP模型层与层之间进行信息传递的数据形式

词向量和词嵌入是指的同一个东西，区别在于词向量是指数字编码技术，词嵌入是指NLP网络之间的数据存在形式

	水果	公司	手机	粮食
$R_{橘子}$	$r_{橘子,水果}$	$r_{橘子,公司}$	$r_{橘子,手机}$	$r_{橘子,粮食}$
$R_{香蕉}$	$r_{香蕉,水果}$	$r_{香蕉,公司}$	$r_{香蕉,手机}$	$r_{香蕉,粮食}$
$R_{苹果}$	$r_{苹果,水果}$	$r_{苹果,公司}$	$r_{苹果,手机}$	$r_{苹果,粮食}$
$R_{小米}$	$r_{小米,水果}$	$r_{小米,公司}$	$r_{小米,手机}$	$r_{小米,粮食}$
$R_{华为}$	$r_{华为,水果}$	$r_{华为,公司}$	$r_{华为,手机}$	$r_{华为,粮食}$

学习后

	水果	公司	手机	粮食
$R_{橘子}$	0.92	0.23	0.02	0.19
$R_{香蕉}$	0.95	0.13	0.09	0.25
$R_{苹果}$	0.96	0.77	0.85	0.15
$R_{小米}$	0.08	0.81	0.98	0.87
$R_{华为}$	0.02	0.93	0.95	0.01

数学形式

$$\begin{bmatrix} V_1 \\ \vdots \\ V_n \end{bmatrix} = \begin{bmatrix} V_{11} & \cdots & V_{1m} \\ \vdots & \ddots & \vdots \\ V_{n1} & \cdots & V_{nm} \end{bmatrix}$$

词表大小为n个Token，特征值数量为m

句子的独热码表示

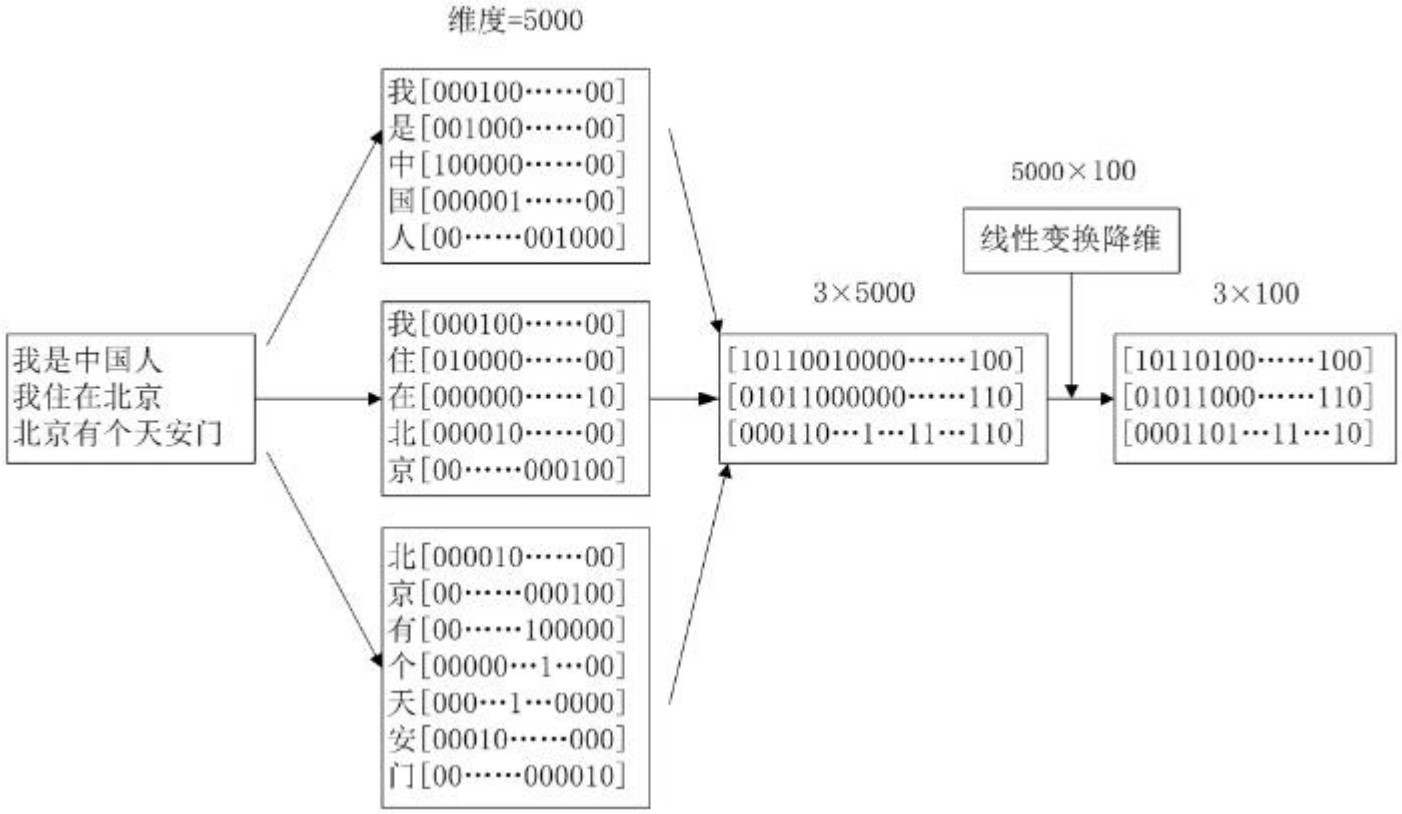
“黄山落叶松叶落山黄”

黄	[1,0,0,0,0]
山	[0,1,0,0,0]
落	[0,0,1,0,0]
叶	[0,0,0,1,0]
松	[0,0,0,0,1]
叶	[0,0,0,1,0]
落	[0,0,1,0,0]
山	[0,1,0,0,0]
黄	[1,0,0,0,0]

方式一：二维的稀疏矩阵

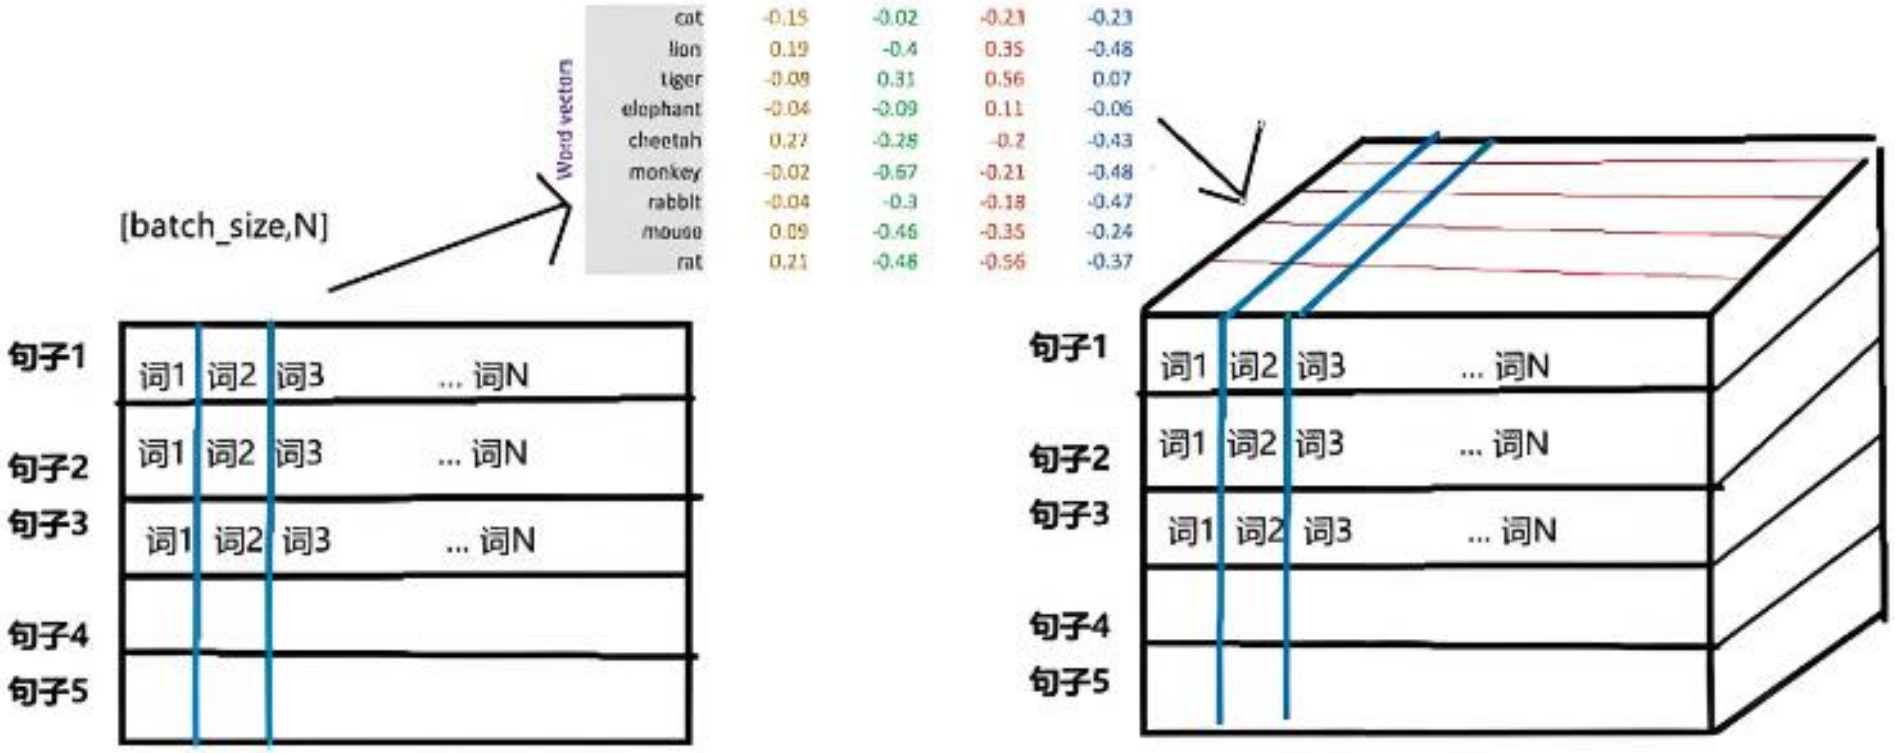
[2,2,2,2,1]

方式二：一维的稠密矩阵



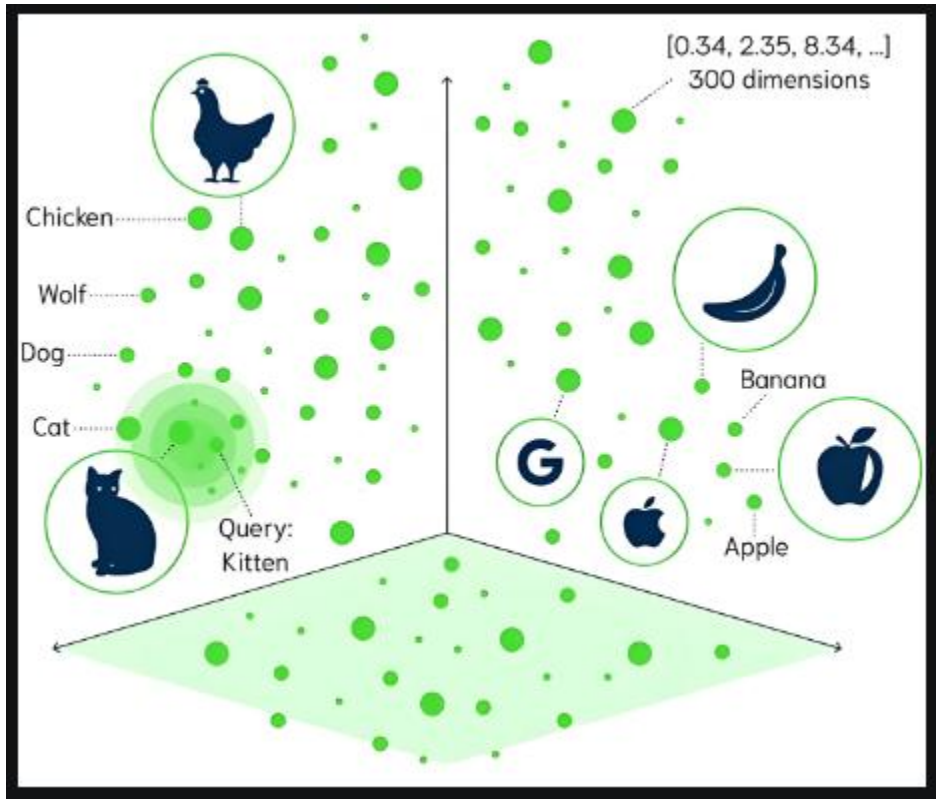
一段话的编码

句子的特征向量表示


Word vectors
cat -0.15 -0.02 -0.23 -0.23
lion 0.19 -0.4 0.35 -0.48
tiger -0.08 0.31 0.56 0.07
elephant -0.04 -0.09 0.11 -0.06
cheetah 0.27 -0.28 -0.2 -0.43
monkey -0.02 -0.67 -0.21 -0.48
rabbit -0.04 -0.3 -0.18 -0.47
mouse 0.09 -0.45 -0.35 -0.24
rat 0.21 -0.48 -0.56 -0.37
[batch_size,N]
句子1
句子2
句子3
句子4
句子5
词1 词2 词3 ... 词N

文本相似度

有了词向量的表示，就可以非常容易的计算文本相似度，一般地，语义相近的词在向量空间上具有相近的位置。



将每个词映射到多维空间中的一个点

余弦相似度

设两个文本的向量为 A 和 B ，那么 A、B 的余弦相似度计算公式如下：

$$\text{Cosine Similarity} = \cos\theta = \frac{A \cdot B}{\|A\| \, \|B\|}$$

$A \cdot B$ 表示向量 A 和 B 的点积，$\sum_{i,j} A_i \cdot B_j$ （i =1~ m ， j =1~ n ）

而||A|| ||B||表示A的模和B的模乘积，$\sqrt{\sum_{i=1}^{m}(A_i)^2} \times \sqrt{\sum_{j=1}^{n}(B_j)^2}$

cos(0°)=1
cos(90°)=0
cos(180°)=-1

欧式距离

$$d = \sqrt{\sum_{i-1}^{n}(x_i - y_i)^2}$$

距离越短，则两个文本越相似

Jaccard相似度

$$\text{EJ}(A,B) = \frac{A \cdot B}{\|A\|^2 + \|B\|^2 - A \cdot B}$$

其中， $A \cdot B$ 表示向量乘积，||A||和||B||分别表示向量 A 和 B 的模。

狭义定义： $\mathbf{J(A,B)} = \frac{|A \cap B|}{|A \cup B|}$

值越大，则两个文本越相似

47

文本相似度计算例题

例11-1：根据上节的表2，计算华为和苹果的余弦相似度 和广义Jaccard相似度。

解：根据表2可知，令华为的词向量 A =[0.02, 0.93, 0.95, 0.01]，苹果的词向量 B =[0.96, 0.77, 0.85, 0.15]

$A \cdot B$ =0.02×0.96+0.93×0.77+0.95×0.85+0.01×0.15=1.5443

||A||= $\sqrt{0.02^2 + 0.93^2 + 0.95^2 + 0.01^2} = \sqrt{1.7679}$ =1.3296

||B||= $\sqrt{0.96^2 + 0.77^2 + 0.85^2 + 0.15^2} = \sqrt{2.2595}$ =1.5032

余弦相似度： $\cos\theta = \frac{A \cdot B}{\|A\| \, \|B\|}$ =0.7727

广义Jaccard相似度： $\mathrm{EJ}(A,B) = \frac{A \cdot B}{||A||^2 + ||B||^2 - A \cdot B} = \frac{1.5443}{1.7679 + 2.2595 - 1.5443}$ =0.6219

例11-2：计算以下两个文本的Jaccard相似度，文本1 “我爱北京天安门”，文本2 “天安门雄伟壮阔让人不得不爱” （不考虑词频）。

解：文本1的集合 A ={我，爱，北，京，天，安，门}

文本2的集合 B ={天，安，门，雄，伟，壮，阔，让，人，不，得，爱}

$A \cap B$ ={爱，天，安，门}

$A \cup B$ ={我，爱，北，京，天，安，门，雄，伟，壮，阔，让，人，不，得}

Jaccard相似度： $\mathrm{J(A,B)} = \frac{|A \cap B|}{|A \cup B|} = \frac{4}{15}$ =0.2667

	水果	公司	手机	粮食
$R_{橘子}$	0.92	0.23	0.02	0.19
$R_{香蕉}$	0.95	0.13	0.09	0.25
$R_{苹果}$	0.96	0.77	0.85	0.15
$R_{小米}$	0.08	0.81	0.98	0.87
$R_{华为}$	0.02	0.93	0.95	0.01

用python构建以下2句话的词袋模型并计算相似度

句子1：词袋模型是自然语言处理和信息检索中的一种常用文本表示方法。它将文本表示为一个词的集合，忽略词语的顺序和语法结构，只关注词语的出现频率或其他统计量。

句子2：词袋模型是一种将文本数据转换为数值型向量的方法，其中文本被视为一个由词语组成的无序集合，每个词语的出现都被独立考虑，而不考虑其上下文或顺序。

48

Transformer重点回顾

1、注意力机制

第十二卦：否卦 （否：否之匪人，不利君子貞，大往小來。）

天地否

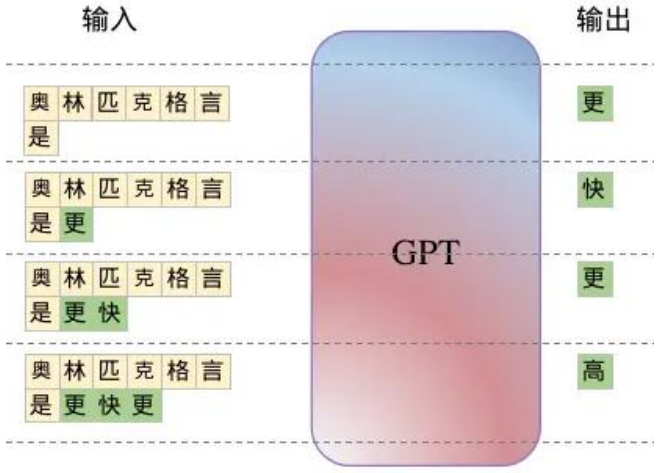
乾上
- 上九：傾否，先否後喜。
- 九五：休否，大人吉；其亡其亡，系于苞桑。
- 九四：有命無咎，疇離祉。

坤下
- 六三：包羞。
- 六二：包承，小人吉，大人否，亨。
- 初六：拔茅茹，以其匪；貞吉，亨。

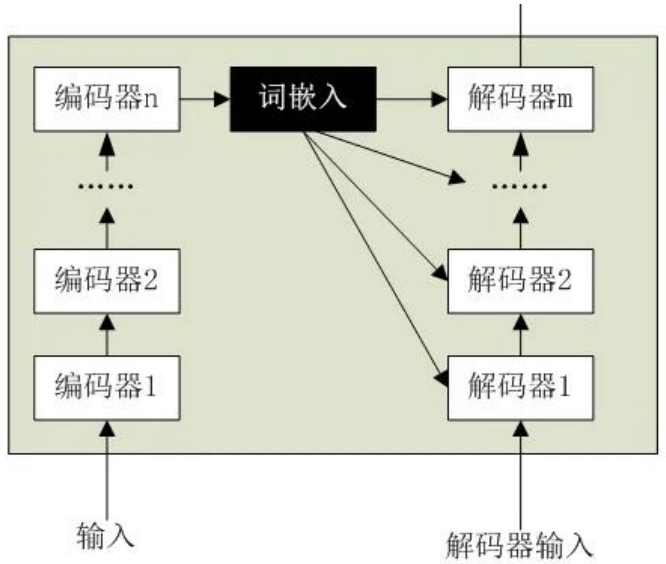
乾卦

- 上九，亢龙，有悔。
- **九五，飞龙在天，利见大人。**
- 九四，或跃在渊，无咎。
- 九三，君子终日乾乾，夕惕若厉，无咎。
- 九二，见龙在田，利见大人。
- 初九，潜龙，勿用。

2、自回归生成技术

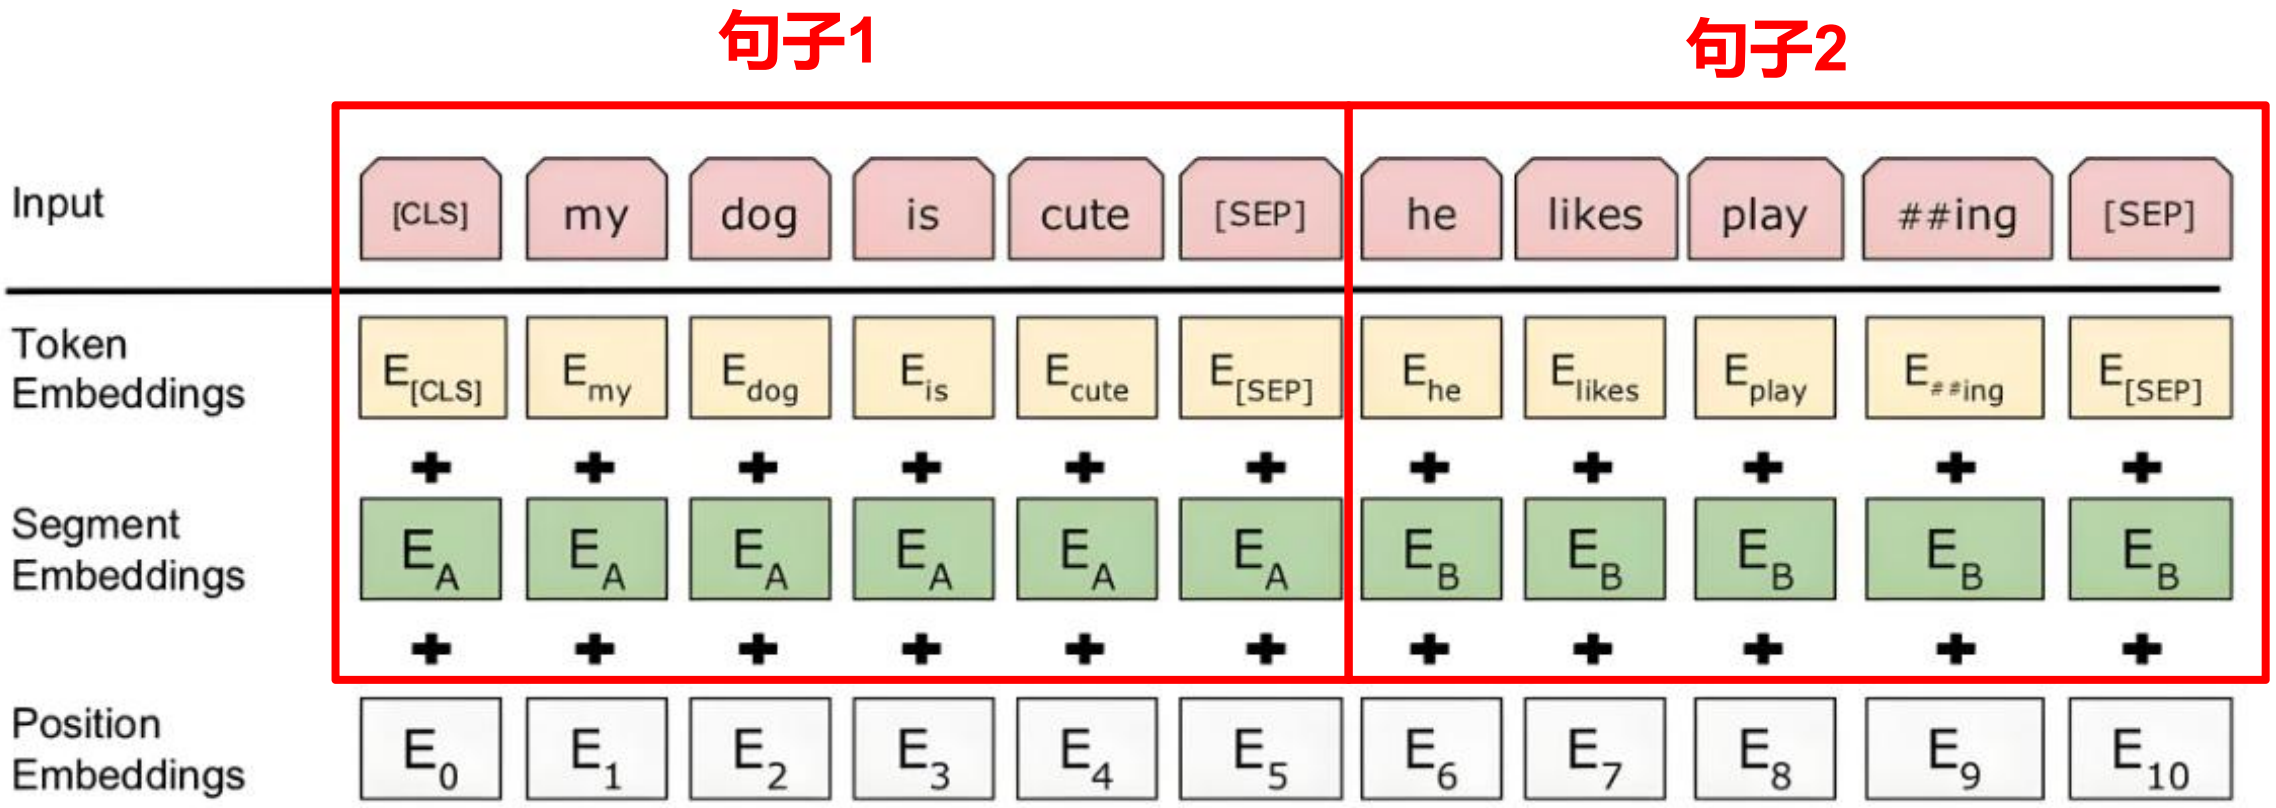


3、整体结构

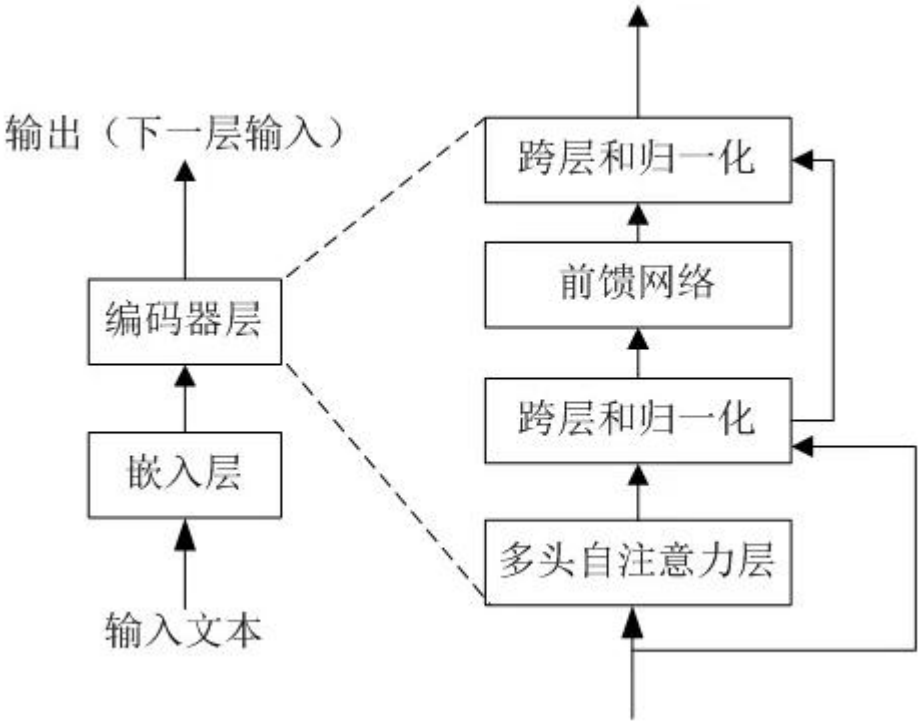


Transformer的自然语言编码

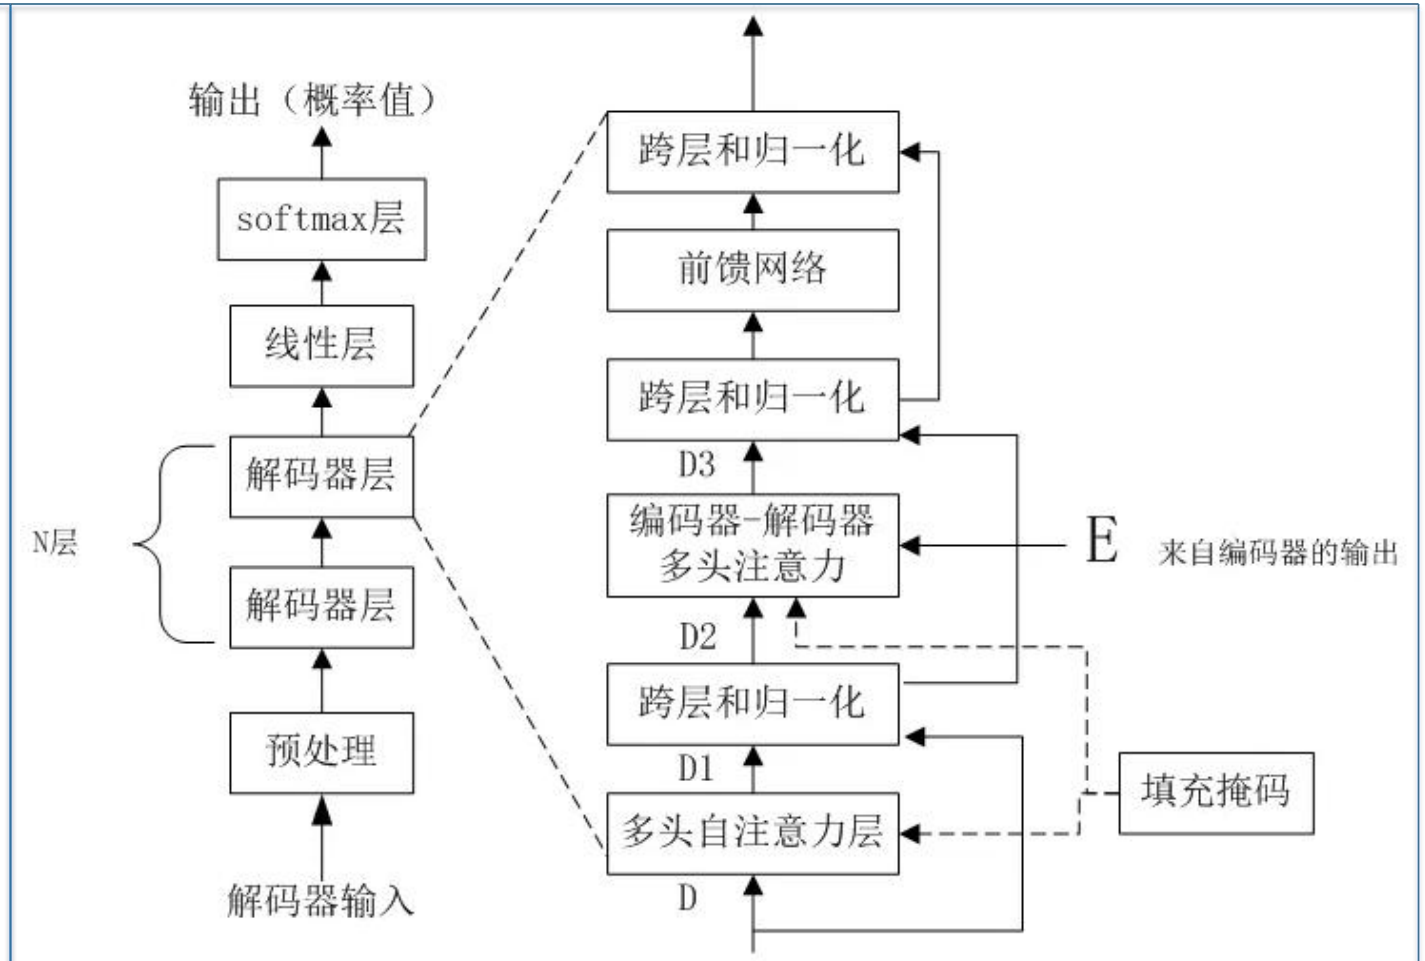




Transformer重点回顾

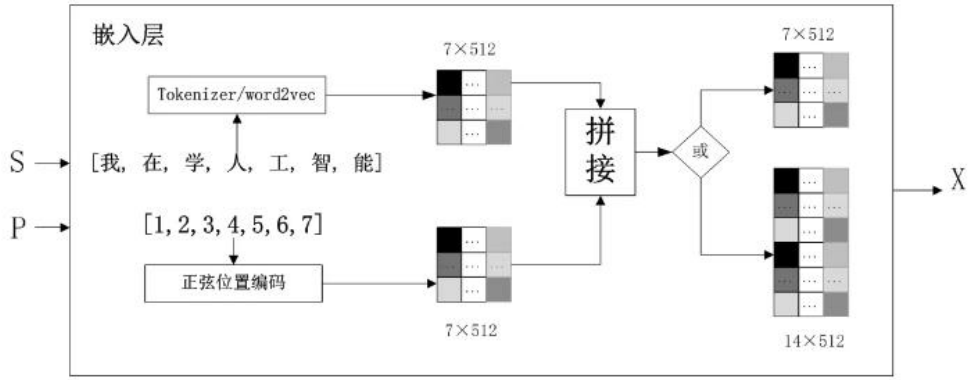


单个编码器层的展开



单个解码器层的展开

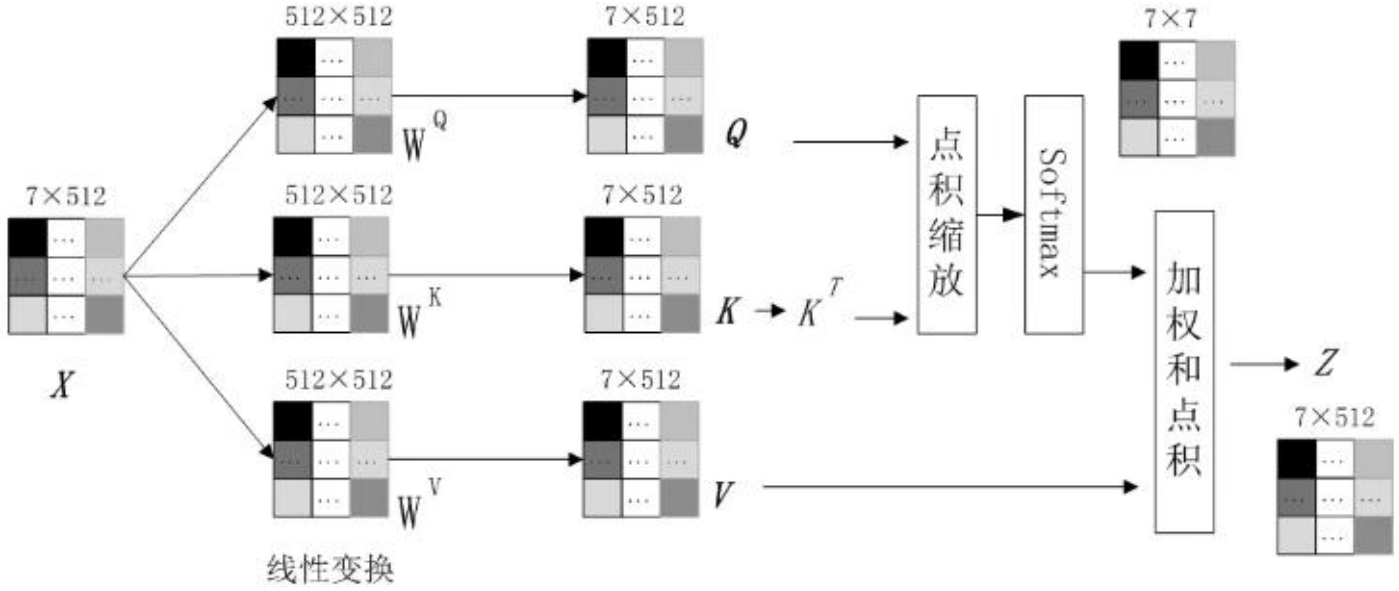
Transformer重点回顾



文本编码（词嵌入）

	采用编码器	采用解码器
BERT系列	√	×
GPT系列	×	√
T5系列	√	√

三类模型



自注意力机制

		我	在	学	人	工	智	能
2	我							
3	在							
4	学							
5	人							
6	工							
7	智							
8	能							

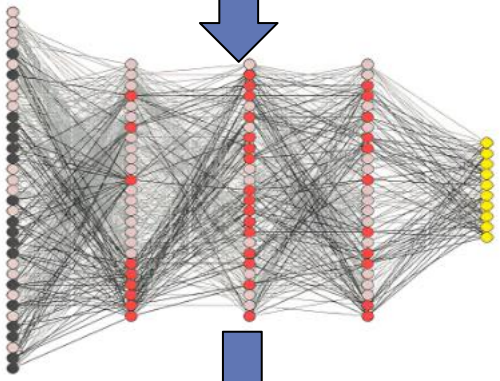
AIGC 与 与搜索引擎的区别

AIGC（Artificial Intelligence Generated Content，人工智能生成内容），是指利用人工智能技术，计算机自动生成各种形式的内容，如文章、音乐、图片、视频等。AIGC它与以前的搜索引擎技术不同，搜索引擎只能获取已经存在的内容或者知识，如某个网页、数据库中的某段文字。

输入提示词

枯藤老树昏鸦，小桥流水人家，古道西风瘦马，夕阳西下，断肠人在天涯

计算



输出生成内容

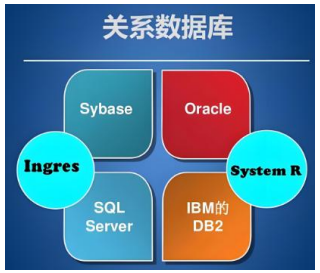


AIGC

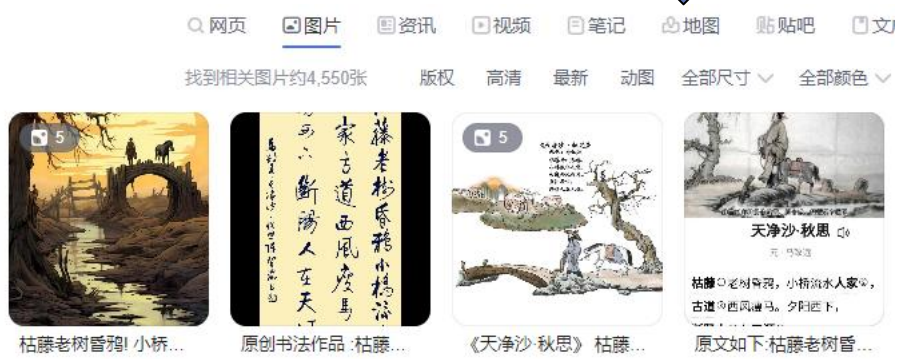
枯藤老树昏鸦，小桥流水人家，古道西风瘦马，夕阳西下，断肠人在天涯

输入检索词

数据库







输出保存的内容

搜索引擎

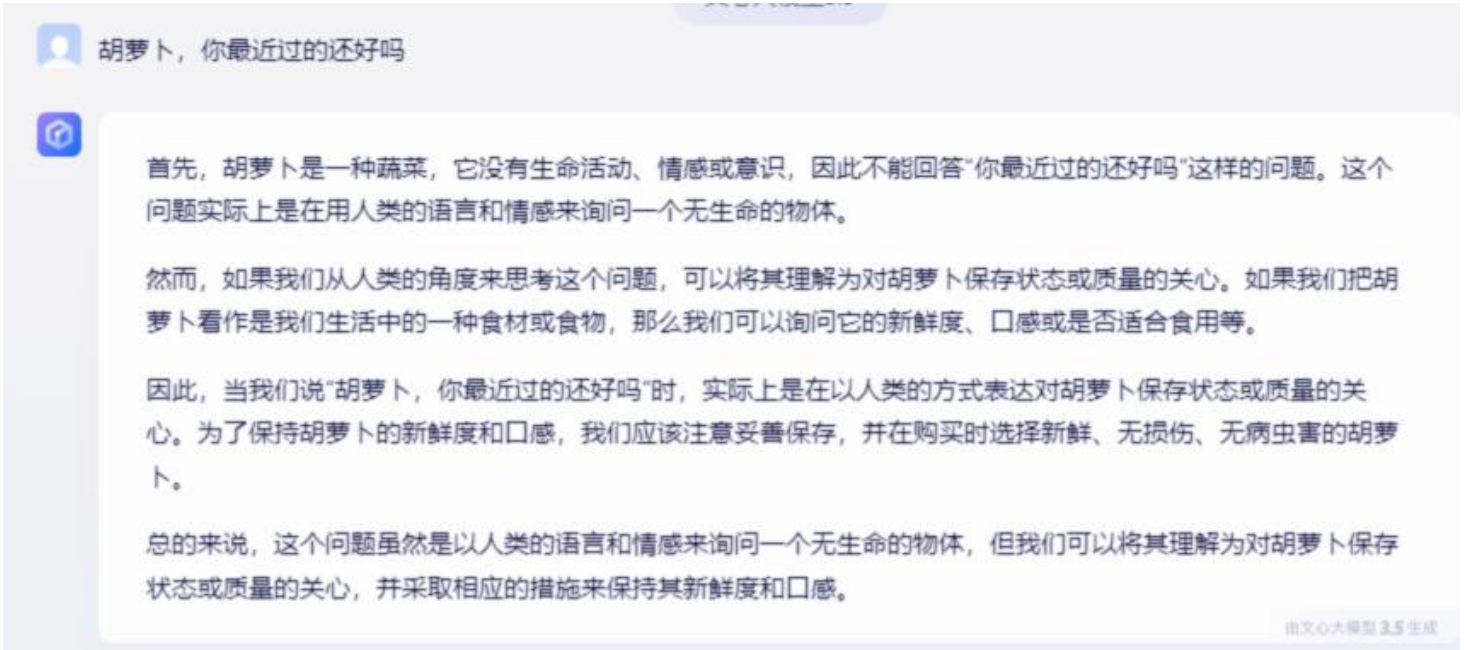
AIGC 的局限与挑战



1、AIGC的原创性：几乎为零。

2、AIGC的可解释性：缺乏，说的比想的快。

3、语义理解：长度有限，包括时间跨度和文本长度



挑战与思考

1、AIGC的生成速度远超人类，话语权是谁?

2、如何识别AI生成的内容?

3、AI造假怎么办?

4、AI错了怎么办?

5、陷入困局怎么办



LLM中大的含义



LLM（Large Language Model，大语言模型），是特指用于执行NLP任务的语言模型。大的含义：

1、训练数据大：以T为单位
数据来源领域广大，涵盖人类现有研究的所有门类

2、参数规模大：以千亿为单位，
以Transformer结构为基础

3、耗资巨大：以百万美元为单位

GPT4
训练数据：13万亿（13T）条
参数规模：1.8万亿
一次训练成本：6300万美元

涌现能力：当一种系统在复杂性增加到某一临界点时，会出现其子系统或较小规模版本中未曾存在的行为或特性

使用LLM应注意的问题：
1、模型不是越大越好，尤其是在专业领域
2、数据偏差与偏见依然存在
3、隐私和数据保护依然是关键
4、训练数据的伦理要求

GAI

GAI（Generative Artificial Intelligence，生成式人工智能），是特指能生成全新内容的AI，其生成的内容就是前面所提的AIGC，AIGC侧重内容生成的来源，而GAI侧重AI系统的功能特点。



需要注意的问题

1、自回归生成技术，带有随机性

2、不是搜索引擎



GAI不认识自己

大模型	生成结果	是否正确
文心一言	写一首人工智能的五言绝句 人工智能舞，巧思妙如神。问它如何处，云在九霄云。	正确
Claude	写一首人工智能的五言绝句 人工智能腾飞时 智慧之光耀千里 穿梭虚拟无疆域 洞见未来可期许	错误
chat4.0	写一首人工智能的五言绝句 人工蕴奇智，电光织梦境。算法如水深，未来共人前。	正确
chat4o—mini	写一首人工智能的五言绝句 智慧闪烁光辉现， 数据海洋思绪连。 虚拟心灵共此刻， 人机共舞未来篇。	错误
Gemini	写一首人工智能的五言绝句 智械之躯，非肉非血。算法为魂，算尽乾坤。无情无欲，永不停息。未来之光，亦是之感。	错误
智谱AI	写一首人工智能的五言绝句 智能光环绕乾坤，千里之外解问津。互助交流成大道，共谋发展驰飞轮。	错误
通义千问	写一首人工智能的五言绝句 智能照万象，代码织千行。数据给世界，算法映光芒。	正确

不同的AI生成不同的内容

AGI的特征

AGI（Artificial General Intelligence，通用人工智能），是指机器能够完成人类能够完成的任何智力任务的能力。它旨在实现一般的认知能力，能够适应任何情况或目标，是人工智能研究的最终目标之一。AGI能够执行各种复杂的任务，包括学习、计划、解决问题、抽象思维、理解复杂理念等。即通五明。

大五明：工巧明(技术、天文学)、医方明（医学）、声明(文法、文学)、因明(伦理学)、内明(哲学、教育学)
小五明：修辞学、辞藻学、韵律学、戏剧学、星系学

训练要求：1、领域无关　　2、任务无关

挑战与思考

1、超越人类带来的风险?
2、耗能问题怎么解决?
3、AI为人类服务还是人类为AI服务?
4、AI是否能产生意识并觉醒?



终结者?



原子弹?

GPT与ChatGPT



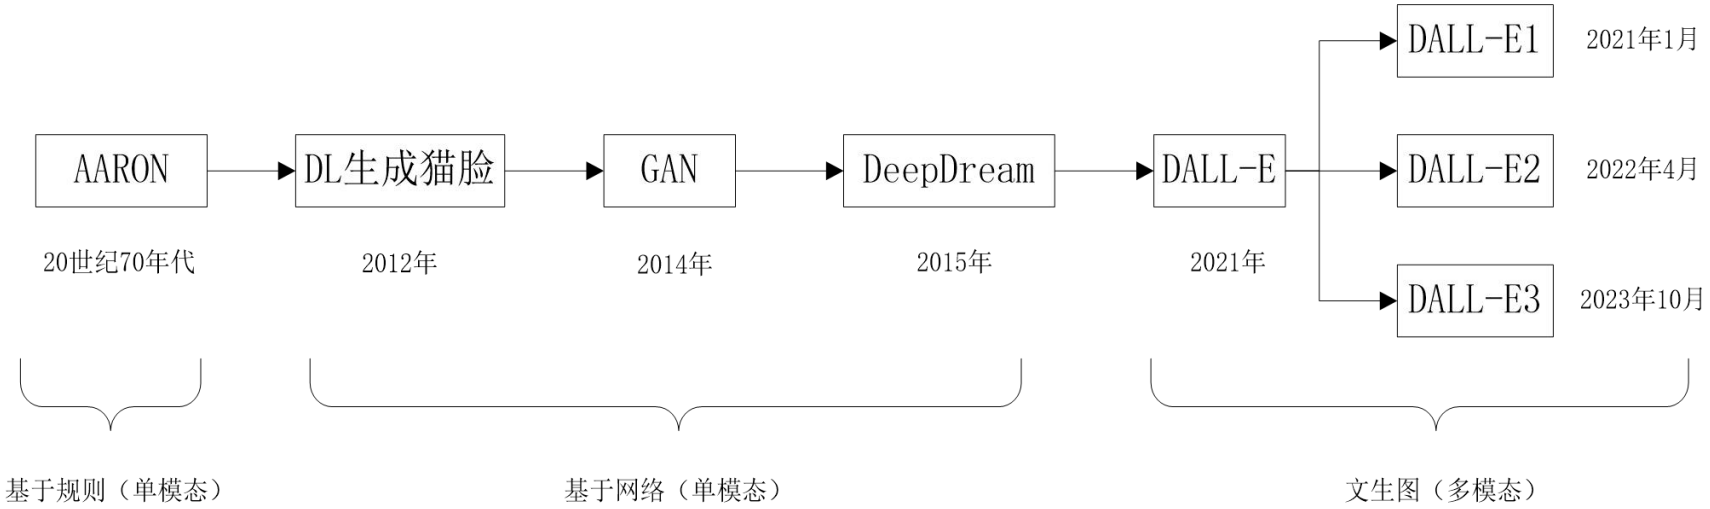
GPT（Generative Pre-trained Transformer），是一个基于Transformer结构的预训练模型。

ChatGPT（Chat Generative Pre-trained Transformer），是一个采用GPT架构的聊天机器人产品

ChatGPT重塑人与机器的交互方式



AI绘画发展历程



里程碑事件

1、20世纪70年代，AARON，通过机械臂进行作画，控制机械臂的是一套计算机程序算法，艺术家哈罗德·科恩

2、2012年，谷歌的吴恩达和Jeff Dean使用卷积神经网络（CNN），基于大量猫脸图片训练出了一个能够生成模糊猫脸的模型

3、2014年，生成式对抗网络（GAN），加拿大蒙特利尔大学伊恩·古德费罗

4、2015年，Deep Dream（深梦），谷歌

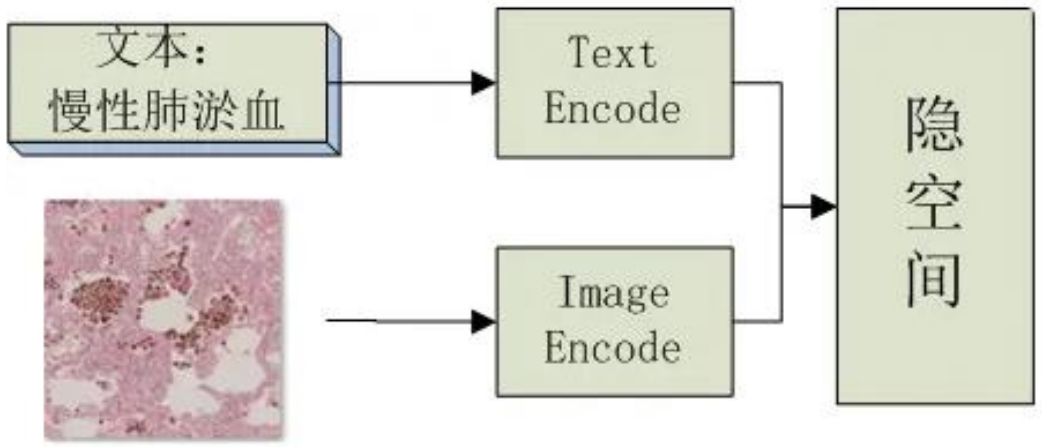
5、2021年，DALL-E，OpenAI

DALL-E1：GPT-3（Transformer） + VAE（自分编码器）

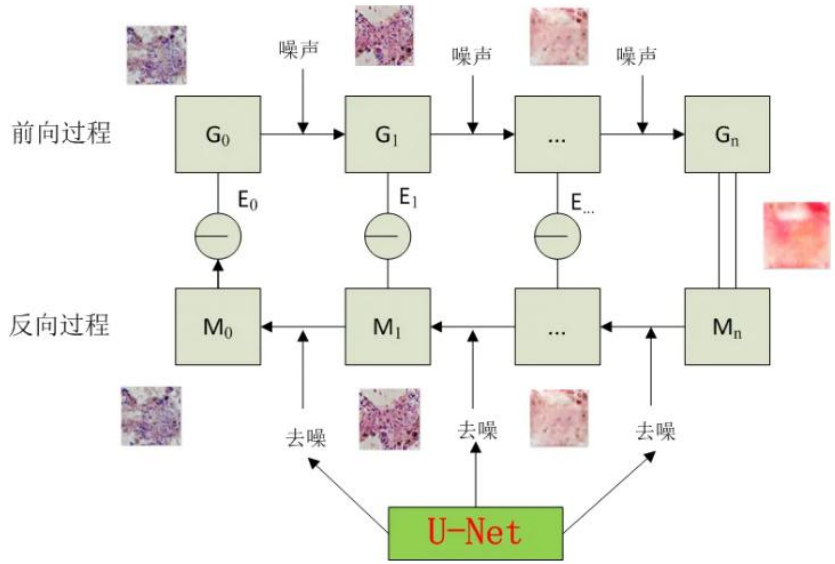
DALL-E2：CLIP（视觉语言预训练模型） + Diffusion（扩散模型）

DALL-E3：CLIP + VAE + Diffusion（扩散模型）

CLIP与扩散模型



CLIP（视觉语言预训练模型）： 文本信息通过文本编码器进行编码，图像信息通过图像编码器进行编码，二者的编码信息存入多模态的隐空间中。所谓的隐空间就是数据的一种表示和存储方式，即将现实世界的实体（如本文中的图像、文本）编码为计算机算法可运算的数据格式。文本编码器和图像编码器的参数经过模型训练获得最优值，以实现文本与图像的匹配



前向过程（扩散过程）： 原始图像G_0经过不断的加入高斯噪声生成模糊图像（即打马赛克），经过n步，最终生成一副不再扩散的稳定图像G_n。

反向过程（去噪过程）： 从图像$M_n=G_n$出发，通过带参数的模型U-Net一步步实现去噪过程恢复图像的原始状态，经过n步，最终获得去噪后的图像M_0。这个模型U-Net就是扩散模型。

定制私人助手



私密性：放心提供一些私密的数据，协助记忆，比如工作日程安排、与某人的会面感受、会议记录、旅游照片、与AI日常的聊天记录。

专业性：放心提供专业的语料投喂给自己的私人AI助手，经过训练的AI助手可以解答您专业的、个性化的问题。

专业数据：知识产权保护、涉密、专业壁垒不能分享。

永久性：聊天对话记录永久保存，并作为强化训练的数据，并在任意时刻“唤醒记忆”。

情感陪伴：私人AI助手在跟您长期的陪伴聊天中，不断记忆、训练并进化自己，了解您的爱好、习惯、感兴趣的话题、价值观等，等您老的时候，它将作为情感陪伴发挥自己的作用，陪您唠嗑。到了那时，具身机器人已经普及，您可以给它选择一个您喜欢的造型，而现在训练的“大脑”只需安装到这个躯壳之中。与猫狗这些宠物相比，它还不会死亡。

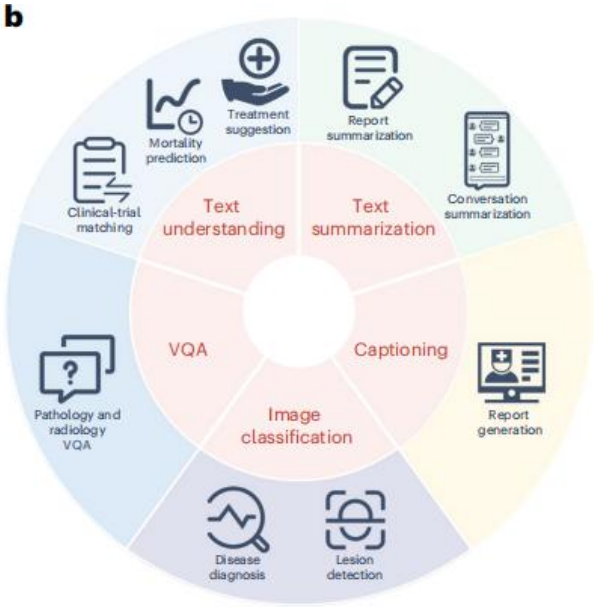
huggingFace国内镜像网站　https://hf-mirror.com/

多模态大语言模型MLLM

多模态大语言模型（Multimodal Large Language Model，MLLM）：够感知不同模态的输入，如图片、文字、声音等，并根据人类给出的指令，以自回归的方式学习上下文并生成回答。MLLM使用了自然语言处理、计算机视觉和语音识别等技术，并将它们整合到一个系统中，从而能够更加准确地理解人类的语言和情感。

模态：任意形式的信息都可以视为一个模态，如文本、图像、语音、光波、气味等





多模态任务



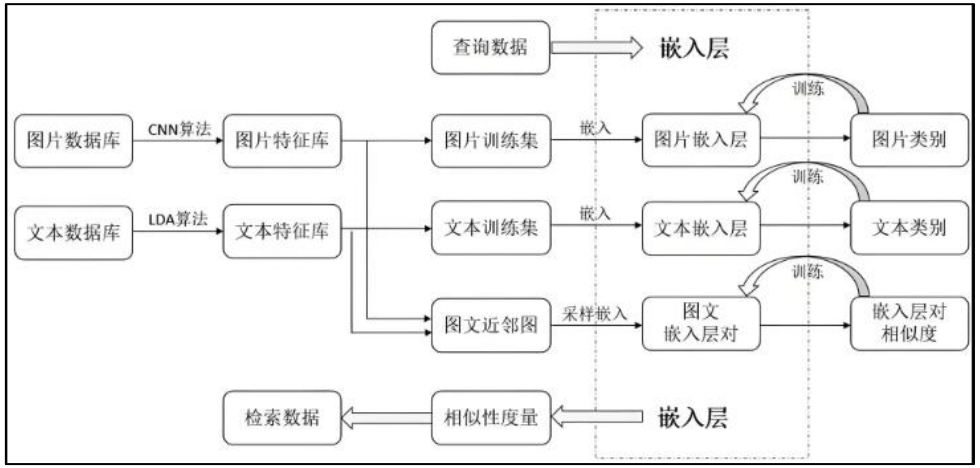
1 图文跨模态检索

2 视觉问答
Visual_Question_Answering, VQA

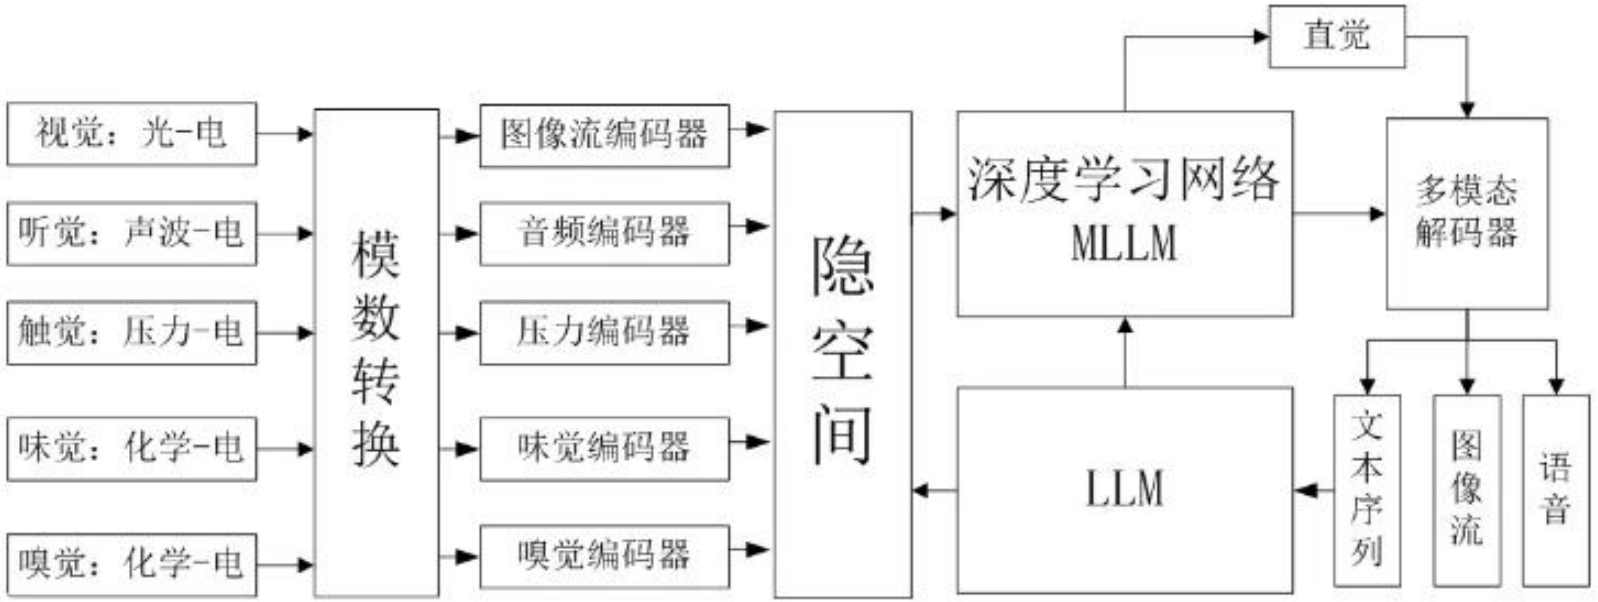
3 文生图（AI 绘画）



4 图像描述及指称表达



MLLM研究思路启发



六感：
视觉、听觉、嗅觉
味觉、触觉、直觉



THANKS